LENON_MERLO_PARTE_1_TCC

March 19, 2026

```
<CENTER>
      <img src="https://professor.uvv.br/Content/img/logo-uvv.png" alt="UVV-LOGO" style = widtl
    </CENTER>
    <CENTER><b>DATA SCIENCE PROJECT</b></CENTER><br/>
    <CENTER><b>WORKFLOW PARTE 1 DO PROJETO</b></CENTER><br/>
```

NOME COMPLETO: LENON OTMAR TONOLI MERLO

LINK PARA SEU PRÓPRIO COLAB: Link

LINK PARA SEU PRÓPRIO GITHUB: Aqui

LINK PARA SEU VÍDEO NO YOUTUBE: Aqui

1 Cenário Fictício:

Prezados(as) alunos(as),

É com entusiasmo que apresento a proposta do **Projeto de Conclusão de Curso (TCC)** para os estudantes do curso de Ciência de Dados da Universidade Vila Velha: o UWine – Clube de Vinhos da UVV.

A proposta do projeto consiste na análise de um Clube de Vinhos universitário fictício, com base em dados simulados, que será totalmente orientado por técnicas e práticas de Ciência de Dados.

Sendo assim, você foi designado como **Consultor em Ciência de Dados** (***Data Science Consultant***) para fazer uma análise completa dos dados dos clientes a partir de um conjunto de dados (Amostra) com mais de 1 milhão de notas fiscais (~ 350 Megabytes). Além disso, há uma entrada diária de aproximadamente umas 5000 novas notas fiscais no sistema.

O objetivo é permitir que cada consultor(a) percorra foco analíticos diferentes dentro do mesmo ecossistema de dados, aplicando modelos de machine learning supervisionado ou não supervisionado, análise preditiva, dashboards interativos, entre outros.

Para garantir organização, profundidade técnica e coerência metodológica no desenvolvimento do ***Projeto UWine***, adotaremos um workflow composto por cinco etapas principais, alinhadas às boas práticas da Ciência de Dados. Cada etapa representa um marco do processo analítico, permitindo

que cada analista avance de forma estruturada do entendimento inicial dos dados até a entrega final dos insights.

2 BIBLIOTECAS E FUNÇÕES E CÓDIGOS

[1]:
```
# Imports

import pandas as pd
import numpy as np
from scipy import stats
from scipy.stats import shapiro, chi2_contingency, f_oneway, ttest_ind, levene
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.utils import resample
import warnings
warnings.filterwarnings('ignore')
```

[2]:
```
CAMINHO_DADOS = "/content/table25.csv"

table = pd.read_csv(CAMINHO_DADOS, index_col=0)

plt.style.use("seaborn-v0_8-darkgrid")
sns.set_palette("husl")
plt.rcParams["figure.figsize"] = (12, 6)
plt.rcParams["font.size"] = 10

n_linhas, n_colunas = table.shape

print("TCC - UVVine: Análise Estatística de Amostragem")
print(f"Base carregada com {n_linhas:,} registros e {n_colunas} variáveis.")
```

```
TCC - UVVine: Análise Estatística de Amostragem
Base carregada com 1,120,000 registros e 23 variáveis.
```

[3]:
```
display(table.head())

n_linhas, n_colunas = table.shape
print(f"Dimensão da base: {n_linhas:,} linhas e {n_colunas} colunas.")

table.info()

valores_nulos = table.isna().sum().sort_values(ascending=False)
valores_nulos = valores_nulos[valores_nulos > 0]

if len(valores_nulos) > 0:
    display(valores_nulos)
else:
```

```python
print("Não foram identificados valores ausentes na base de dados.")
```

```
   NOTA FISCAL    REGIÃO       SEXO              ESTADO CIVIL  DEPENDENTES  \
0      5836177   SUDESTE  MASCULINO                    CASADO            1
1      1981138   SUDESTE  MASCULINO                  SOLTEIRO            1
2      6293910   SUDESTE  MASCULINO  DESQUITADO(A) / VIÚVO(A)            0
3      5656569   SUDESTE  MASCULINO                  SOLTEIRO            1
4      8642826  NORDESTE   FEMININO                    CASADO            1

   RENDA BRUTO (R$)                              OPINIÃO DO CLIENTE  \
0           8012.27      Gostei do atendimento prestado pela UVVine
1          21897.71          Nada demais, serviço regular na UVVine
2          19840.24  Foi indiferente minha experiência com a UVVine
3           3167.32      Gostei do atendimento prestado pela UVVine
4           9061.20       Fiquei satisfeito com o serviço da UVVine

   NOTA DE SATISFAÇÃO (%)  MEAN: alcohol  MEAN: malic_acid  …  \
0                  68.680      14.044677          1.484295  …
1                  69.589      11.738318          0.930835  …
2                  68.680      12.241004          2.756235  …
3                  68.680      12.905167          3.585136  …
4                  70.397      12.550841          4.746782  …

   MEAN: total_phenols  MEAN: flavanoids  MEAN: nonflavanoid_phenols  \
0             2.919873          1.898048                    0.455349
1             2.763588          1.048772                    0.220046
2             2.580669          0.981184                    0.355254
3             2.489790          1.418967                    0.303763
4             4.464296          2.827265                    0.341251

   MEAN: proanthocyanins  MEAN: color_intensity  MEAN: hue  \
0               1.917438               4.139711   0.934844
1               1.589010               2.859220   0.766190
2               1.591051               6.238933   0.844660
3               1.788616               2.404009   1.086255
4               0.625414               2.856048   1.183745

   MEAN: od280/od315_of_diluted_wines  MEAN: proline  TIPO DA CONTA  \
0                            1.961535     955.701693            VIP
1                            2.315932     680.732234          PRIME
2                            3.868414     659.935656          PRIME
3                            3.854773     718.578770      ESSENTIAL
4                            2.444532     498.733620          PRIME

   TOTAL (R$)
0     1043.59
1     1315.85
```

```
2     1390.81
3      223.70
4     1451.78

[5 rows x 23 columns]
```

```
Dimensão da base: 1,120,000 linhas e 23 colunas.
<class 'pandas.core.frame.DataFrame'>
Index: 1120000 entries, 0 to 1119999
Data columns (total 23 columns):
 #   Column                              Non-Null Count    Dtype
---  ------                              --------------    -----
 0   NOTA FISCAL                         1120000 non-null  int64
 1   REGIÃO                              1120000 non-null  object
 2   SEXO                                1120000 non-null  object
 3   ESTADO CIVIL                        1120000 non-null  object
 4   DEPENDENTES                         1120000 non-null  int64
 5   RENDA BRUTO (R$)                    1120000 non-null  float64
 6   OPINIÃO DO CLIENTE                  1120000 non-null  object
 7   NOTA DE SATISFAÇÃO (%)              1120000 non-null  float64
 8   MEAN: alcohol                       1120000 non-null  float64
 9   MEAN: malic_acid                    1120000 non-null  float64
 10  MEAN: ash                           1120000 non-null  float64
 11  MEAN: alcalinity_of_ash             1120000 non-null  float64
 12  MEAN: magnesium                     1120000 non-null  float64
 13  MEAN: total_phenols                 1120000 non-null  float64
 14  MEAN: flavanoids                    1120000 non-null  float64
 15  MEAN: nonflavanoid_phenols          1120000 non-null  float64
 16  MEAN: proanthocyanins               1120000 non-null  float64
 17  MEAN: color_intensity               1120000 non-null  float64
 18  MEAN: hue                           1120000 non-null  float64
 19  MEAN: od280/od315_of_diluted_wines  1120000 non-null  float64
 20  MEAN: proline                       1120000 non-null  float64
 21  TIPO DA CONTA                       1120000 non-null  object
 22  TOTAL (R$)                          1120000 non-null  float64
dtypes: float64(16), int64(2), object(5)
memory usage: 205.1+ MB
Não foram identificados valores ausentes na base de dados.
```

[4]:
```
qualitativas = ["REGIÃO", "SEXO", "ESTADO CIVIL", "OPINIÃO DO CLIENTE", "TIPO␣
↪DA CONTA"]

quantitativas = [
    "DEPENDENTES",
    "RENDA BRUTO (R$)",
    "NOTA DE SATISFAÇÃO (%)",
    "TOTAL (R$)",
    "MEAN: alcohol",
```

```
    "MEAN: malic_acid",
    "MEAN: ash",
    "MEAN: alcalinity_of_ash",
    "MEAN: magnesium",
    "MEAN: total_phenols",
    "MEAN: flavanoids",
    "MEAN: nonflavanoid_phenols",
    "MEAN: proanthocyanins",
    "MEAN: color_intensity",
    "MEAN: hue",
    "MEAN: od280/od315_of_diluted_wines",
    "MEAN: proline",
]
```

[5]:
```
RESULTADOS = {}

def calcular_tamanho_amostra_proporcao(N, z=1.96, p=0.5, e=0.05):
    """Calcula o tamanho mínimo da amostra para população finita e infinita."""
    numerador = (z ** 2) * p * (1 - p)
    denominador = e ** 2
    n = numerador / denominador

    n_ajustado = n / (1 + (n / N))
    return int(np.ceil(n)), int(np.ceil(n_ajustado))
```

[6]:
```
# Paleta padrão dos gráficos
PLOT_COLORS = {
    "main_line": "tab:blue",
    "ref_line": "tab:orange",
    "ideal_pt": "tab:green",
    "zero": "tab:red",
    "ci": "tab:purple",
    "li": "tab:red",
    "ls": "tab:purple",
    "hist": "tab:blue",
    "kde": "tab:orange",
}
```

3 Workflow: Detalhamento das Atividades

##Atividade A1 (Link): Estratificação amostral da população

Nesta etapa, busca-se determinar o tamanho ideal da amostra para representar adequadamente a população disponível, considerando nível de confiança e margem de erro.

Também são avaliadas características da distribuição dos dados (outliers e testes estatísticos), garantindo base metodológica sólida para as próximas análises.

3.0.1 Atividade A1.1: Determinação do tamanho da amostra

Nesta etapa, o tamanho ideal da amostra é definido com base na estabilização do erro-padrão da média da variável `TOTAL (R$)`. Para isso, são simulados diferentes tamanhos amostrais, identificando-se o menor tamanho `n` para o qual o erro-padrão estimado é menor ou igual ao erro-padrão médio.

[7]:
```
def AtividadeA1_1():
    y = table["TOTAL (R$)"].dropna()
    N = len(y)

    tamanhos = np.arange(100, 200_100, 100)
    erros_padrao = np.zeros(len(tamanhos), dtype=float)

    rng = np.random.default_rng(42)
    R_pequeno = 15
    R_grande = 3

    for idx, n in enumerate(tamanhos):
        R = R_pequeno if n <= 50_000 else R_grande
        se_rep = []

        for _ in range(R):
            seed = int(rng.integers(0, 1_000_000_000))
            amostra = y.sample(n=n, replace=False, random_state=seed)
            se_rep.append(amostra.std(ddof=1) / np.sqrt(n))

        erros_padrao[idx] = np.mean(se_rep)

    se_medio = float(erros_padrao.mean())
    media_total = float(y.mean())

    ic_inf = media_total - 1.96 * se_medio
    ic_sup = media_total + 1.96 * se_medio

    idx_ideal = int(np.where(erros_padrao <= se_medio)[0][0])
    n_ideal = int(tamanhos[idx_ideal])
    se_ideal = float(erros_padrao[idx_ideal])

    RESULTADOS["A1.1"] = {
        "N": int(N),
        "media_total": media_total,
        "se_medio": se_medio,
        "ic_95": (float(ic_inf), float(ic_sup)),
        "tamanho_ideal": n_ideal,
        "tamanhos": tamanhos,
        "erros_padrao": erros_padrao,
        "se_ideal": se_ideal,
    }
```

```
    print(f"População disponível (N): {N:,}")
    print(f"Média de TOTAL (R$): {media_total:.2f}")
    print(f"Erro-padrão-médio: {se_medio:.6f}")
    print(f"IC 95% da média: [{ic_inf:.2f}, {ic_sup:.2f}]")
    print(f"Tamanho ideal da amostra: {n_ideal:,}")
```

[8]:
```
AtividadeA1_1()
resultado = RESULTADOS["A1.1"]
```

```
População disponível (N): 1,120,000
Média de TOTAL (R$): 851.19
Erro-padrão-médio: 3.751394
IC 95% da média: [843.83, 858.54]
Tamanho ideal da amostra: 51,400
```

[9]:
```
plt.figure(figsize=(11, 6))
plt.plot(
    resultado["tamanhos"],
    resultado["erros_padrao"],
    color=PLOT_COLORS["main_line"],
    linewidth=2.8,
    alpha=0.95,
    label="Erro padrão",
)
plt.axhline(
    resultado["se_medio"],
    color=PLOT_COLORS["ref_line"],
    linestyle="--",
    linewidth=2.5,
    alpha=0.95,
    label=f'SE médio = {resultado["se_medio"]:.4f}',
)
plt.scatter(
    resultado["tamanho_ideal"],
    resultado["se_ideal"],
    color=PLOT_COLORS["ideal_pt"],
    s=110,
    zorder=6,
    edgecolor="black",
    linewidth=0.8,
    label=f'n ideal = {resultado["tamanho_ideal"]:,}',
)
plt.title("Convergência do erro-padrão da média da variável TOTAL (R$)",␣
 ↪fontsize=15, fontweight="bold")
plt.xlabel("Tamanho da amostra (n)", fontsize=12)
plt.xscale("log")
```

```
plt.ylabel("Erro padrão da média", fontsize=12)
plt.grid(alpha=0.22)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
plt.show()
```

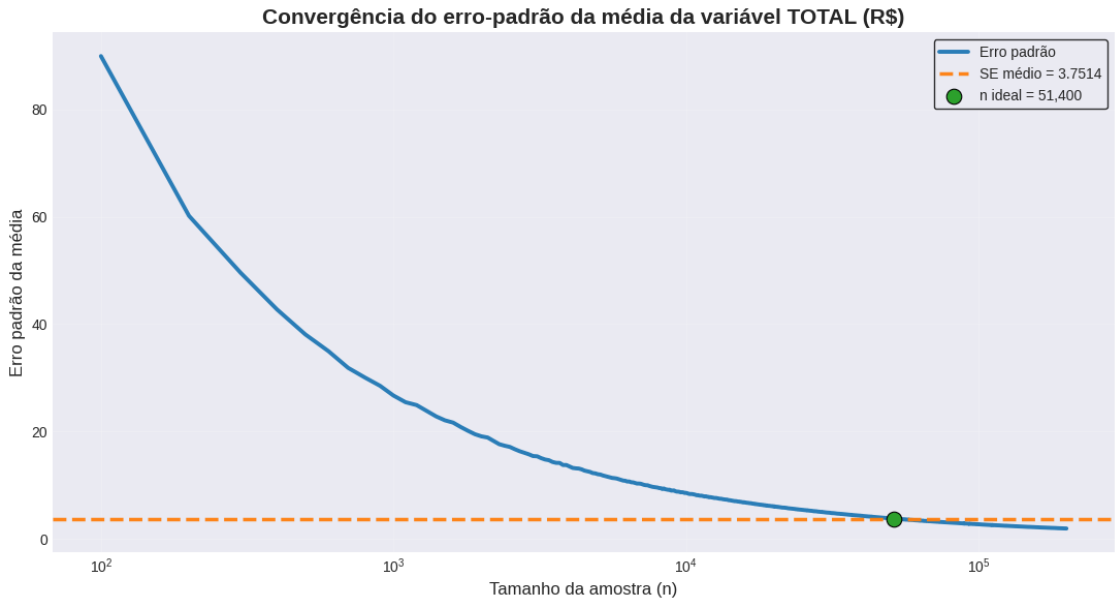

Os resultados evidenciam que o erro-padrão da média decresce conforme o tamanho amostral aumenta, apresentando estabilização progressiva ao longo das simulações. Considerando o critério `SE(n) <= SE médio`, o tamanho ideal da amostra foi estabelecido em `n = 51.400`, sendo este o valor adotado nas etapas posteriores do estudo.

3.0.2 Atividade A1.2: Análise dos outliers

Nesta etapa, realiza-se a análise da variável `NOTA DE SATISFAÇÃO (%)` com o objetivo de identificar concentração excessiva de valores, possíveis outliers e o comportamento geral da distribuição.

[11]:
```
serie = table["NOTA DE SATISFAÇÃO (%)"]

resumo = serie.describe().to_frame(name="Valor")
frequencias = serie.value_counts().head(10).to_frame(name="Frequência")
proporcoes = (serie.value_counts(normalize=True).head(10) * 100).
 ↪to_frame(name="Percentual (%)")

display(resumo)
print(f"Quantidade de valores únicos: {serie.nunique():,}")
display(frequencias)
display(proporcoes.round(3))
```

```
              Valor
count  1.120000e+06
mean   6.896948e+01
std    1.356640e+00
min    6.868000e+01
25%    6.868000e+01
50%    6.868000e+01
75%    6.868000e+01
max    9.211200e+01

Quantidade de valores únicos: 202

                        Frequência
NOTA DE SATISFAÇÃO (%)
68.680                     1042915
69.185                        1306
68.882                        1306
69.084                        1260
68.983                        1236
70.094                        1234
69.589                        1226
69.387                        1225
69.690                        1207
68.781                        1202

                        Percentual (%)
NOTA DE SATISFAÇÃO (%)
68.680                          93.117
69.185                           0.117
68.882                           0.117
69.084                           0.112
68.983                           0.110
70.094                           0.110
69.589                           0.109
69.387                           0.109
69.690                           0.108
68.781                           0.107
```

[13]:
```
top_valores = (serie.value_counts(normalize=True).head(10) * 100).sort_values()

plt.figure(figsize=(10, 6))
bars = plt.barh(
    top_valores.index.astype(str),
    top_valores.values,
    color=sns.color_palette("Blues", len(top_valores))
)

plt.title("Percentual dos 10 valores mais frequentes de NOTA DE SATISFAÇÃO␣
 ↪(%)", fontsize=14, fontweight="bold")
```

```
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Nota", fontsize=11)
plt.grid(axis="x", alpha=0.20)

for bar in bars:
    largura = bar.get_width()
    plt.text(largura + 0.2, bar.get_y() + bar.get_height() / 2, f"{largura:.
 ↪2f}%", va="center", fontsize=10)

plt.tight_layout()
sns.despine()
plt.show()
```

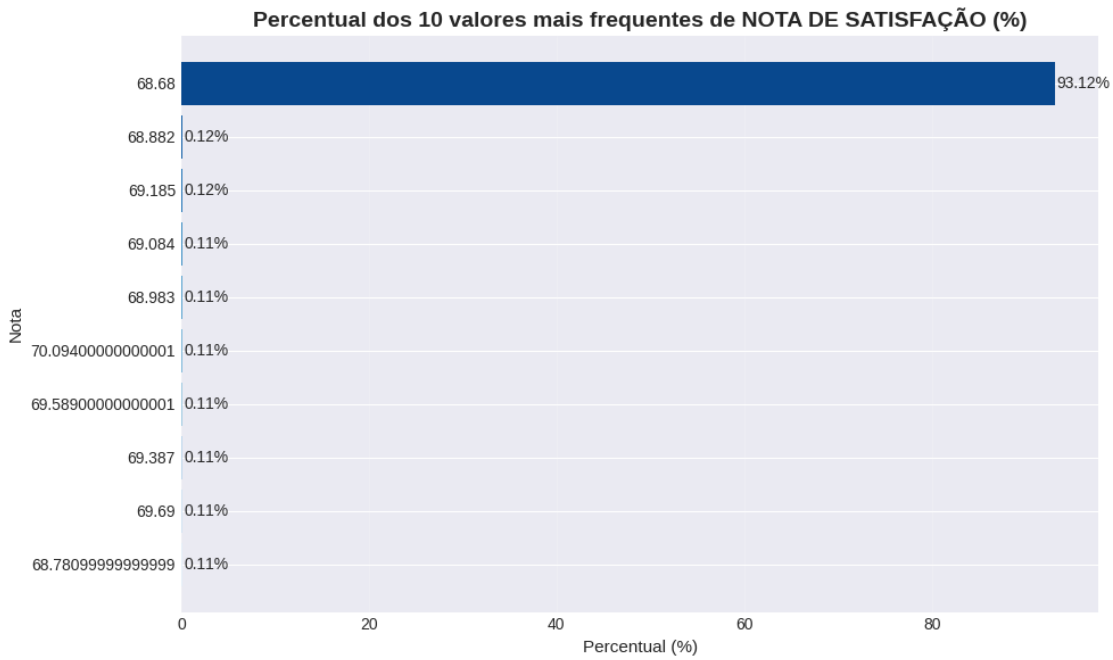

[14]:
```
# Funções auxiliaras

def identificar_outliers_iqr(dados, coluna):
    serie = dados[coluna].dropna()

    q1 = float(serie.quantile(0.25))
    q3 = float(serie.quantile(0.75))
    iqr = float(q3 - q1)

    li = float(q1 - 1.5 * iqr)
    ls = float(q3 + 1.5 * iqr)
```

```
    outliers = dados[(dados[coluna] < li) | (dados[coluna] > ls)]

    return {
        "q1": q1,
        "q3": q3,
        "iqr": iqr,
        "li": li,
        "ls": ls,
        "qtd_outliers": int(len(outliers)),
    }


def winsorizar_por_limites(dados, coluna, li, ls):
    return dados[coluna].clip(lower=li, upper=ls)
```

[15]:
```
# Execução da análise

def AtividadeA1_2():
    variaveis = ["RENDA BRUTO (R$)", "NOTA DE SATISFAÇÃO (%)", "TOTAL (R$)"]
    n_registros = len(table)

    resumo = []
    limites = {}
    table_wins = table.copy()
    impacto = []

    for var in variaveis:
        info = identificar_outliers_iqr(table, var)
        perc_outliers = (info["qtd_outliers"] / n_registros) * 100

        diagnostico = (
            "IQR adequado"
            if info["iqr"] > 0
            else "IQR = 0; usar apenas para diagnóstico"
        )

        resumo.append({
            "Variável": var,
            "Q1": info["q1"],
            "Q3": info["q3"],
            "IQR": info["iqr"],
            "LI": info["li"],
            "LS": info["ls"],
            "Qtd. Outliers": info["qtd_outliers"],
            "% Outliers": perc_outliers,
            "Diagnóstico": diagnostico,
        })
```

```
        limites[var] = info

        media_antes = float(table[var].mean())
        dp_antes = float(table[var].std())

        if info["iqr"] > 0:
            table_wins[var] = winsorizar_por_limites(table, var, info["li"],␣
↪info["ls"])
            media_depois = float(table_wins[var].mean())
            dp_depois = float(table_wins[var].std())
            acao = "Winsorizada"
        else:
            media_depois = media_antes
            dp_depois = dp_antes
            acao = "Mantida"

        impacto.append({
            "Variável": var,
            "Ação": acao,
            "Média antes": media_antes,
            "Média depois": media_depois,
            "DP antes": dp_antes,
            "DP depois": dp_depois,
        })

    resumo_df = pd.DataFrame(resumo).sort_values("% Outliers", ascending=False)
    impacto_df = pd.DataFrame(impacto)

    RESULTADOS["A1.2"] = {
        "resumo": resumo_df,
        "impacto_winsorizacao": impacto_df,
        "limites_iqr": limites,
        "table_wins": table_wins,
    }

    print("Análise de outliers concluída.")
    print(f"Variáveis analisadas: {len(variaveis)}")
    print(f"Maior percentual de outliers: {resumo_df.iloc[0]['Variável']}␣
↪({resumo_df.iloc[0]['% Outliers']:.2f}%)")
```

[16]:
```
# Execução e tabelas

AtividadeA1_2()

resultado = RESULTADOS["A1.2"]
```

```
resumo_exibicao = resultado["resumo"].copy()
resumo_exibicao[["Q1", "Q3", "IQR", "LI", "LS", "% Outliers"]] = (
    resumo_exibicao[["Q1", "Q3", "IQR", "LI", "LS", "% Outliers"]].round(2)
)

impacto_exibicao = resultado["impacto_winsorizacao"].copy()
impacto_exibicao[["Média antes", "Média depois", "DP antes", "DP depois"]] = (
    impacto_exibicao[["Média antes", "Média depois", "DP antes", "DP depois"]].
 ↪round(2)
)

display(resumo_exibicao)
display(impacto_exibicao)
```

```
Análise de outliers concluída.
Variáveis analisadas: 3
Maior percentual de outliers: RENDA BRUTO (R$) (17.39%)

                 Variável       Q1       Q3      IQR       LI        LS  \
0        RENDA BRUTO (R$)  3240.67  8069.25  4828.58 -4002.20  15312.13
2              TOTAL (R$)   323.92  1068.84   744.92  -793.46   2186.22
1  NOTA DE SATISFAÇÃO (%)    68.68    68.68     0.00    68.68     68.68

   Qtd. Outliers  % Outliers                            Diagnóstico
0         194771       17.39                           IQR adequado
2         106903        9.54                           IQR adequado
1          77085        6.88  IQR = 0; usar apenas para diagnóstico

                 Variável         Ação  Média antes  Média depois  DP antes  \
0        RENDA BRUTO (R$)  Winsorizada      7722.33       6737.46   6639.55
1  NOTA DE SATISFAÇÃO (%)      Mantida        68.97         68.97      1.36
2              TOTAL (R$)  Winsorizada       851.19        768.82    852.08

   DP depois
0    4613.48
1       1.36
2     628.37
```

[17]:
```
# Gráficos

df_plot = table[["RENDA BRUTO (R$)", "NOTA DE SATISFAÇÃO (%)", "TOTAL (R$)"]].
 ↪dropna().sample(
    n=min(50000, len(table)),
    random_state=42
)

for var in df_plot.columns:
    info = resultado["limites_iqr"][var]
```

```
fig, axes = plt.subplots(
    2,
    1,
    figsize=(11, 6.5),
    gridspec_kw={"height_ratios": [1, 3]},
    sharex=True
)

sns.boxplot(
    x=df_plot[var],
    color="#9ecae1",
    linewidth=1.2,
    fliersize=2.5,
    ax=axes[0]
)

axes[0].axvline(info["li"], color="#d62728", linestyle="--", linewidth=2,␣
↪label="LI")
axes[0].axvline(info["ls"], color="#9467bd", linestyle="--", linewidth=2,␣
↪label="LS")
axes[0].set_title(f"Análise de outliers - {var}", fontsize=14,␣
↪fontweight="bold")
axes[0].set_ylabel("")
axes[0].legend(frameon=True, edgecolor="black")

sns.histplot(
    df_plot[var],
    bins=40,
    stat="density",
    color="#6baed6",
    edgecolor="white",
    alpha=0.55,
    ax=axes[1]
)

sns.kdeplot(
    df_plot[var],
    color="#08519c",
    linewidth=2.2,
    ax=axes[1]
)

axes[1].axvline(info["li"], color="#d62728", linestyle="--", linewidth=1.8)
axes[1].axvline(info["ls"], color="#9467bd", linestyle="--", linewidth=1.8)
axes[1].set_xlabel(var, fontsize=11)
axes[1].set_ylabel("Densidade", fontsize=11)
```

```
axes[1].grid(alpha=0.20)

plt.tight_layout()
sns.despine()
plt.show()
```

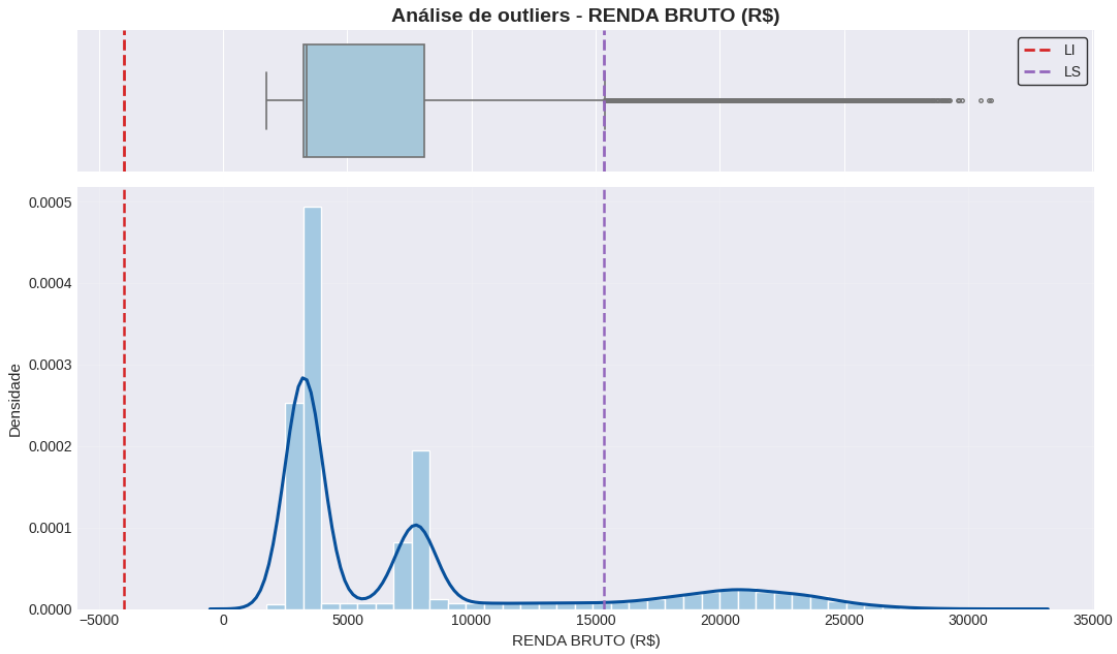

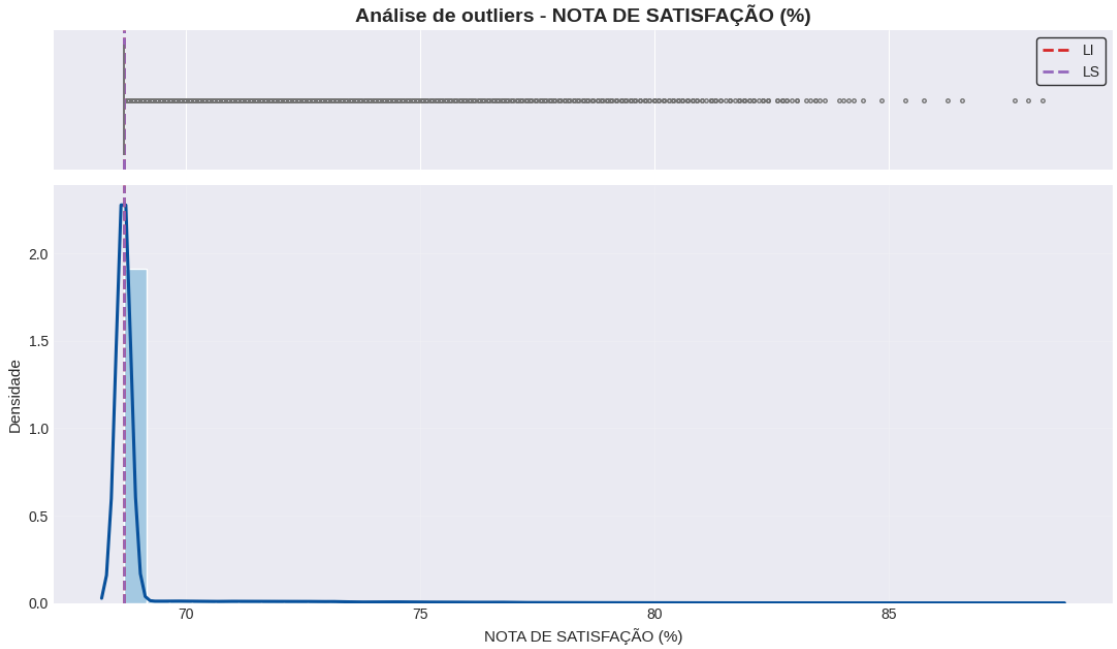

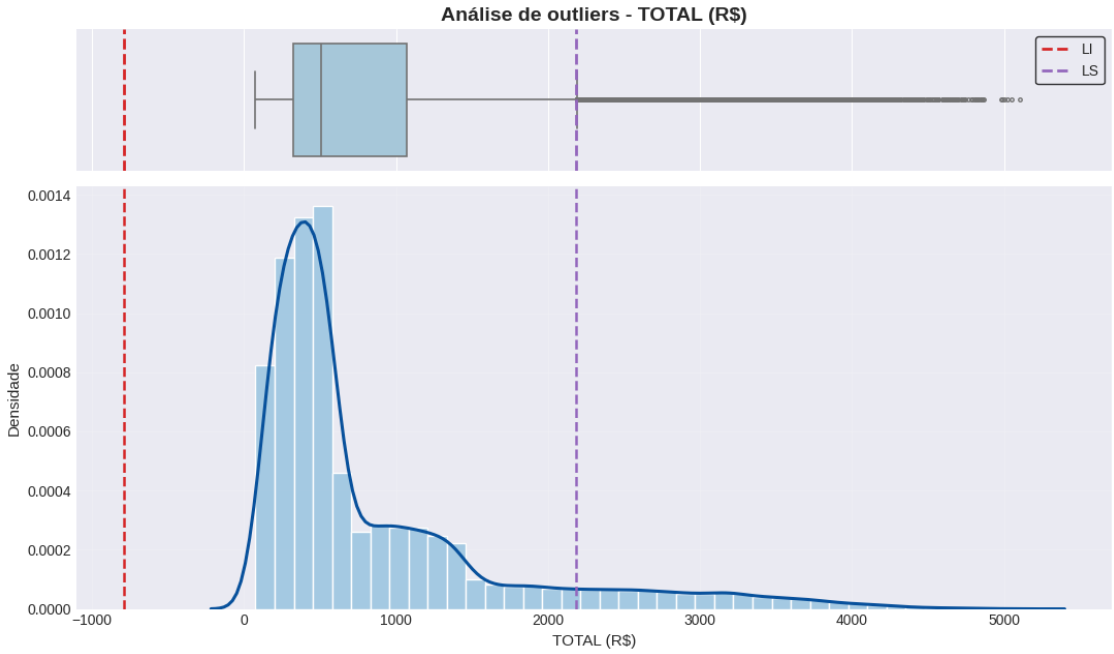

A análise de outliers pelo método IQR identificou valores extremos nas variáveis `RENDA BRUTO (R$)` e `TOTAL (R$)`, com maior incidência em `RENDA BRUTO (R$)` (`17,39%`). Ambas apresentaram assimetria à direita, justificando a criação de uma versão winsorizada para análises comparativas e maior robustez estatística.

Já a variável `NOTA DE SATISFAÇÃO (%)` apresentou forte concentração em torno de `68,68`, resultando em `IQR = 0`. Nesse caso, o método IQR mostrou-se inadequado para tratamento de outliers, razão pela qual essa variável foi mantida apenas para fins descritivos, sem winsorização.

Assim, a estratégia adotada foi manter a base original e utilizar a versão winsorizada apenas nas variáveis em que o procedimento se mostrou metodologicamente apropriado.

###Atividade A1.3: Testes de Hipóteses (Link)

Nesta etapa, avalia-se se a amostra ideal obtida na Atividade A1.1 representa adequadamente a população para a variável `TOTAL (R$)`. Para isso, são realizados o diagnóstico de normalidade, o teste de hipótese para comparação entre média amostral e média populacional, a validação por bootstrap e a análise do impacto da winsorização sobre os resultados.

[18]:
```
def AtividadeA1_3():
    alpha = 0.05
    z_95 = 1.96
    B = 3000
    y_col = "TOTAL (R$)"

    if "A1.1" not in RESULTADOS or "tamanho_ideal" not in RESULTADOS["A1.1"]:
        raise ValueError("Execute a Atividade A1.1 antes desta etapa.")
```

```
n_ideal = int(RESULTADOS["A1.1"]["tamanho_ideal"])

y_full = table[y_col].dropna()
N = len(y_full)

mu_pop = float(y_full.mean())
sd_pop = float(y_full.std(ddof=1))
se_pop = sd_pop / np.sqrt(N)

n_norm = min(5000, N)
y_norm = y_full.sample(n=n_norm, random_state=42)

sh_stat, sh_p = shapiro(y_norm)
decisao_normalidade = "Rejeita normalidade" if sh_p <= alpha else "Não␣
↪rejeita normalidade"

y_sample = y_full.sample(n=n_ideal, random_state=123)
mu_s = float(y_sample.mean())
sd_s = float(y_sample.std(ddof=1))
se_s = sd_s / np.sqrt(n_ideal)

z_stat = (mu_s - mu_pop) / se_s if se_s > 0 else np.nan
p_val = 2 * (1 - stats.norm.cdf(abs(z_stat))) if np.isfinite(z_stat) else␣
↪np.nan
decisao_teste = "Não rejeita H0" if p_val > alpha else "Rejeita H0"

ic_inf = mu_s - z_95 * se_s
ic_sup = mu_s + z_95 * se_s

rng = np.random.default_rng(42)
y_vals = y_sample.values
n = len(y_vals)

boot_means = np.empty(B, dtype=float)
for b in range(B):
    idx = rng.integers(0, n, size=n)
    boot_means[b] = y_vals[idx].mean()

ci_b_inf = float(np.percentile(boot_means, 2.5))
ci_b_sup = float(np.percentile(boot_means, 97.5))

diff_obs = mu_s - mu_pop
boot_diff = boot_means - mu_pop
ci_d_inf = float(np.percentile(boot_diff, 2.5))
ci_d_sup = float(np.percentile(boot_diff, 97.5))
```

```
p_boot = 2 * min((boot_diff <= 0).mean(), (boot_diff >= 0).mean())
p_boot = float(min(1.0, p_boot))

impacto_outliers = None

if "A1.2" in RESULTADOS and "limites_iqr" in RESULTADOS["A1.2"]:
    limites_total = RESULTADOS["A1.2"]["limites_iqr"].get(y_col)

    if limites_total:
        li = limites_total["li"]
        ls = limites_total["ls"]

        y_wins = winsorizar_por_limites(table, y_col, li, ls)

        idx_sample = y_sample.index
        y_orig = y_full.loc[idx_sample].values
        y_wins_sample = y_wins.loc[idx_sample].values

        t_stat, p_t = ttest_ind(y_orig, y_wins_sample, equal_var=False)
        diff_ow = float(y_orig.mean() - y_wins_sample.mean())

        boot_dw = np.empty(B, dtype=float)
        for b in range(B):
            idxb = rng.integers(0, n, size=n)
            boot_dw[b] = y_orig[idxb].mean() - y_wins_sample[idxb].mean()

        ci_dw_inf = float(np.percentile(boot_dw, 2.5))
        ci_dw_sup = float(np.percentile(boot_dw, 97.5))

        impacto_outliers = {
            "li": li,
            "ls": ls,
            "media_original": float(y_orig.mean()),
            "media_winsorizada": float(y_wins_sample.mean()),
            "diferenca": diff_ow,
            "p_value_welch": float(p_t),
            "ic95_diff": (ci_dw_inf, ci_dw_sup),
            "boot_diff": boot_dw,
        }

RESULTADOS["A1.3"] = {
    "variavel": y_col,
    "alpha": alpha,
    "B": B,
    "N": int(N),
    "n_ideal": int(n_ideal),
    "populacao": {
```

```
            "media": mu_pop,
            "dp": sd_pop,
            "se": float(se_pop),
        },
        "normalidade": {
            "n_amostra": int(n_norm),
            "shapiro_stat": float(sh_stat),
            "shapiro_p": float(sh_p),
            "decisao": decisao_normalidade,
            "amostra": y_norm,
        },
        "amostra_ideal": {
            "media": mu_s,
            "dp": sd_s,
            "se": float(se_s),
            "ic95": (float(ic_inf), float(ic_sup)),
            "valores": y_sample,
        },
        "teste_media": {
            "z": float(z_stat),
            "p_value": float(p_val),
            "decisao": decisao_teste,
            "diff_obs": float(diff_obs),
        },
        "bootstrap": {
            "medias": boot_means,
            "diffs": boot_diff,
            "ic95_media": (ci_b_inf, ci_b_sup),
            "ic95_diff": (ci_d_inf, ci_d_sup),
            "p_boot": float(p_boot),
        },
        "impacto_outliers": impacto_outliers,
    }

    print("Análise de hipóteses concluída.")
    print(f"Variável analisada: {y_col}")
    print(f"Amostra ideal utilizada: {n_ideal:,}")
    print(f"Teste principal: {decisao_teste} (p = {p_val:.4f})")
```

[19]:
```
AtividadeA1_3()
resultado = RESULTADOS["A1.3"]
```

```
Análise de hipóteses concluída.
Variável analisada: TOTAL (R$)
Amostra ideal utilizada: 51,400
Teste principal: Não rejeita H0 (p = 0.5644)
```

[20]:
```
resumo_a13 = pd.DataFrame(
    [
        {
            "Etapa": "Normalidade",
            "Estatística": resultado["normalidade"]["shapiro_stat"],
            "p-valor": resultado["normalidade"]["shapiro_p"],
            "Decisão": resultado["normalidade"]["decisao"],
        },
        {
            "Etapa": "Teste da média",
            "Estatística": resultado["teste_media"]["z"],
            "p-valor": resultado["teste_media"]["p_value"],
            "Decisão": resultado["teste_media"]["decisao"],
        },
        {
            "Etapa": "Bootstrap",
            "Estatística": resultado["teste_media"]["diff_obs"],
            "p-valor": resultado["bootstrap"]["p_boot"],
            "Decisão": "Diferença inclui 0 no IC"
            if resultado["bootstrap"]["ic95_diff"][0] <= 0 <=␣
 ↪resultado["bootstrap"]["ic95_diff"][1]
            else "Diferença não inclui 0 no IC",
        },
    ]
)

display(resumo_a13.round(4))
```

```
            Etapa  Estatística  p-valor                   Decisão
0     Normalidade       0.7503   0.0000       Rejeita normalidade
1  Teste da média       0.5764   0.5644            Não rejeita H0
2       Bootstrap       2.1693   0.5540  Diferença inclui 0 no IC
```

[21]:
```
comparacao_medias = pd.DataFrame(
    [
        {
            "Grupo": "População",
            "N": resultado["N"],
            "Média": resultado["populacao"]["media"],
            "DP": resultado["populacao"]["dp"],
            "SE": resultado["populacao"]["se"],
        },
        {
            "Grupo": "Amostra ideal",
            "N": resultado["n_ideal"],
            "Média": resultado["amostra_ideal"]["media"],
            "DP": resultado["amostra_ideal"]["dp"],
```

```
            "SE": resultado["amostra_ideal"]["se"],
        },
    ]
)

display(comparacao_medias.round(4))
```

```
           Grupo        N     Média        DP      SE
0      População  1120000  851.1867  852.0839  0.8051
1  Amostra ideal    51400  853.3560  853.3210  3.7638
```

[22]:
```
y_norm = resultado["normalidade"]["amostra"]

fig, axes = plt.subplots(1, 2, figsize=(13, 5))

sns.histplot(
    y_norm,
    bins=40,
    stat="density",
    color="#9ecae1",
    edgecolor="white",
    alpha=0.60,
    ax=axes[0],
)
sns.kdeplot(
    y_norm,
    color="#08519c",
    linewidth=2.2,
    ax=axes[0],
)

axes[0].set_title("Distribuição amostral de TOTAL (R$)", fontsize=13,␣
 ↪fontweight="bold")
axes[0].set_xlabel("TOTAL (R$)")
axes[0].set_ylabel("Densidade")
axes[0].grid(alpha=0.20)

stats.probplot(y_norm, dist="norm", plot=axes[1])
axes[1].set_title("QQ-plot da amostra", fontsize=13, fontweight="bold")
axes[1].grid(alpha=0.20)

plt.tight_layout()
sns.despine()
plt.show()
```

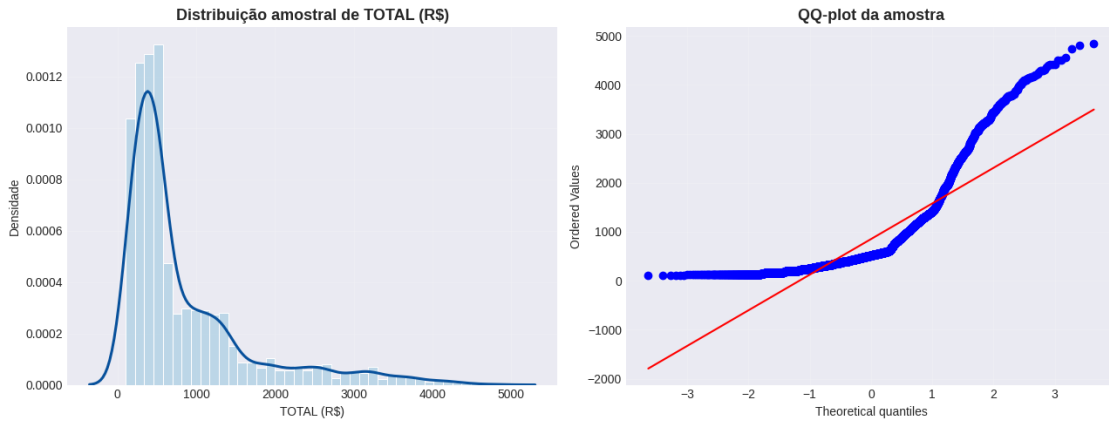

[23]:
```
boot_diff = resultado["bootstrap"]["diffs"]
ci_inf, ci_sup = resultado["bootstrap"]["ic95_diff"]

plt.figure(figsize=(11, 5))

sns.histplot(
    boot_diff,
    bins=40,
    stat="density",
    color="#a1d99b",
    edgecolor="white",
    alpha=0.65,
)

sns.kdeplot(
    boot_diff,
    color="#2ca02c",
    linewidth=2.3,
)

plt.axvline(0, color="#d62728", linestyle="--", linewidth=2, label="Diferença =␣
↪0")
plt.axvline(ci_inf, color="#9467bd", linestyle=":", linewidth=2, label="IC 95%")
plt.axvline(ci_sup, color="#9467bd", linestyle=":", linewidth=2)

plt.title("Bootstrap da diferença entre média amostral e média populacional",␣
↪fontsize=14, fontweight="bold")
plt.xlabel("Diferença (R$)")
plt.ylabel("Densidade")
plt.grid(alpha=0.20)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
```

```
sns.despine()
plt.show()
```

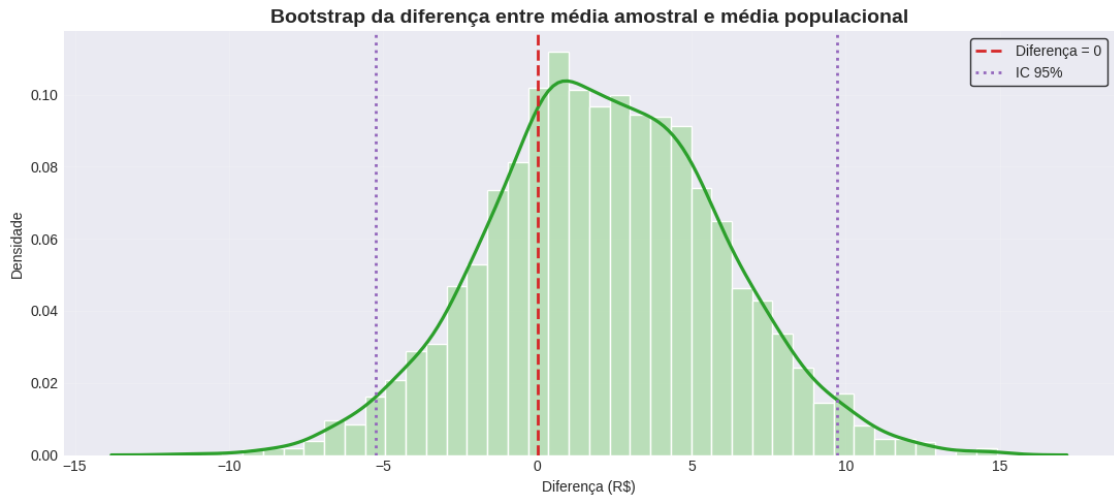

[24]:
```
if resultado["impacto_outliers"] is not None:
    boot_dw = resultado["impacto_outliers"]["boot_diff"]
    ci_inf, ci_sup = resultado["impacto_outliers"]["ic95_diff"]

    plt.figure(figsize=(11, 5))

    sns.histplot(
        boot_dw,
        bins=35,
        stat="density",
        color="#9ecae1",
        edgecolor="white",
        alpha=0.65,
    )

    sns.kdeplot(
        boot_dw,
        color="#3182bd",
        linewidth=2.3,
    )

    plt.axvline(0, color="#d62728", linestyle="--", linewidth=2,␣
↪label="Diferença = 0")
    plt.axvline(ci_inf, color="#9467bd", linestyle=":", linewidth=2, label="IC␣
↪95%")
    plt.axvline(ci_sup, color="#9467bd", linestyle=":", linewidth=2)
```

```
    plt.title("Impacto da winsorização sobre a média de TOTAL (R$)",␣
↪fontsize=14, fontweight="bold")
    plt.xlabel("Diferença entre média original e winsorizada (R$)")
    plt.ylabel("Densidade")
    plt.grid(alpha=0.20)
    plt.legend(frameon=True, edgecolor="black")
    plt.tight_layout()
    sns.despine()
    plt.show()
```

Os resultados da Atividade A1.3 indicaram que a variável `TOTAL (R$)` não apresenta distribuição normal, conforme evidenciado pelo teste de Shapiro-Wilk (`p < 0,001`) e pelo QQ-plot. Ainda assim, considerando o grande tamanho amostral, a inferência sobre a média foi conduzida com base na robustez do Teorema Central do Limite e complementada por bootstrap.

Na comparação entre a população e a amostra ideal (`n = 51.400`), observou-se média populacional de `851,19` e média amostral de `853,36`. O teste de hipótese para a média apresentou `p = 0,5644`, não havendo evidências estatísticas para rejeitar `H0`. De forma consistente, a distribuição bootstrap da diferença entre as médias incluiu o valor zero no intervalo de confiança de 95%, reforçando a conclusão de que a amostra ideal pode ser considerada representativa da população.

Por fim, a análise do impacto da winsorização mostrou diferença relevante entre a média original e a média winsorizada da variável `TOTAL (R$)`, indicando que os valores extremos exercem influência importante sobre essa medida. Assim, os resultados sugerem que a amostra ideal é estatisticamente adequada para representar a população, ao mesmo tempo em que recomendam cautela na interpretação da média em presença de outliers.

A1.3.1: Teste de normalidade Nesta etapa, avalia-se se as principais variáveis numéricas da base apresentam comportamento compatível com a distribuição normal. Para isso, utiliza-se o teste de Shapiro-Wilk em amostras controladas, complementado por histogramas e QQ-plots, permitindo combinar evidência estatística formal e diagnóstico visual.

[25]:
```
# Funções Auxiliares

def teste_shapiro_amostra(serie, n_amostra=5000, alpha=0.05, random_state=42):
    serie = serie.dropna()

    if len(serie) == 0:
        return np.nan, np.nan, "Sem dados", serie

    n_use = min(n_amostra, len(serie))
    amostra = serie.sample(n=n_use, random_state=random_state) if len(serie) >␣
 ↪n_use else serie

    w, p = shapiro(amostra)
    decisao = "Rejeita normalidade" if p < alpha else "Não rejeita normalidade"

    return float(w), float(p), decisao, amostra


def plot_normalidade(amostra, variavel):
    fig, axes = plt.subplots(1, 2, figsize=(13, 5))

    sns.histplot(
        amostra,
        bins=40,
        stat="density",
        color="#9ecae1",
        edgecolor="white",
        alpha=0.60,
        ax=axes[0],
    )
    sns.kdeplot(
        amostra,
        color="#08519c",
        linewidth=2.2,
        ax=axes[0],
    )

    axes[0].set_title(f"Distribuição amostral de {variavel}", fontsize=13,␣
 ↪fontweight="bold")
    axes[0].set_xlabel(variavel)
    axes[0].set_ylabel("Densidade")
    axes[0].grid(alpha=0.20)

    stats.probplot(amostra, dist="norm", plot=axes[1])
    axes[1].set_title(f"QQ-plot de {variavel}", fontsize=13, fontweight="bold")
    axes[1].grid(alpha=0.20)
```

```
    plt.tight_layout()
    sns.despine()
    plt.show()
```

[27]:
```
# Função principal

def AtividadeA1_3_1(n_amostra=5000, alpha=0.05, random_state=42):
    variaveis = ["RENDA BRUTO (R$)", "NOTA DE SATISFAÇÃO (%)", "TOTAL (R$)"]
    resultados = []

    for var in variaveis:
        serie = table[var].dropna()

        media = float(serie.mean())
        dp = float(serie.std(ddof=1))
        skew = float(serie.skew())
        kurt = float(serie.kurtosis())
        n_unicos = int(serie.nunique())

        frequencias = serie.value_counts()
        moda = frequencias.index[0]
        perc_moda = float((frequencias.iloc[0] / len(serie)) * 100)

        w, p, decisao, amostra = teste_shapiro_amostra(
            serie,
            n_amostra=n_amostra,
            alpha=alpha,
            random_state=random_state,
        )

        observacao = ""
        if perc_moda >= 50:
            observacao = "Alta concentração em um único valor"

        resultados.append(
            {
                "Variável": var,
                "N": int(len(serie)),
                "n amostra": int(len(amostra)),
                "W": w,
                "p-valor": p,
                "Decisão": decisao,
                "Média": media,
                "DP": dp,
                "Assimetria": skew,
                "Curtose": kurt,
                "Valores únicos": n_unicos,
```

```
                "Moda": moda,
                "% moda": perc_moda,
                "Observação": observacao,
                "Amostra": amostra,
            }
        )

    df_resultados = pd.DataFrame(resultados)

    RESULTADOS["A1.3.1"] = {
        "tabela": df_resultados.drop(columns=["Amostra"]),
        "amostras": {row["Variável"]: row["Amostra"] for _, row in␣
 ↪df_resultados.iterrows()},
        "parametros": {
            "n_amostra": int(n_amostra),
            "alpha": float(alpha),
            "random_state": int(random_state),
        },
    }

    print("Teste de normalidade concluído.")
    print(f"Variáveis analisadas: {len(variaveis)}")
```

[28]:
```
# Execução + tabela formatada

AtividadeA1_3_1()

resultado = RESULTADOS["A1.3.1"]

tabela_normalidade = resultado["tabela"].copy()
tabela_normalidade[["W", "p-valor", "Média", "DP", "Assimetria", "Curtose", "%␣
 ↪moda"]] = (
    tabela_normalidade[["W", "p-valor", "Média", "DP", "Assimetria", "Curtose",␣
 ↪"% moda"]].round(4)
)

display(tabela_normalidade)
```

```
Teste de normalidade concluído.
Variáveis analisadas: 3

                 Variável        N  n amostra       W  p-valor  \
0        RENDA BRUTO (R$)  1120000       5000  0.7198      0.0
1  NOTA DE SATISFAÇÃO (%)  1120000       5000  0.2177      0.0
2              TOTAL (R$)  1120000       5000  0.7503      0.0

                Decisão      Média         DP  Assimetria  Curtose  \
0  Rejeita normalidade  7722.3349  6639.5538      1.4110   0.6259
```

```
1  Rejeita normalidade    68.9695     1.3566      5.9103  40.2667
2  Rejeita normalidade   851.1867   852.0839      1.9738   3.5316

   Valores únicos     Moda   % moda                          Observação
0          398958  3265.87   0.0048
1             202    68.68  93.1174  Alta concentração em um único valor
2          253143   132.41   0.0057
```

[29]:
```python
for variavel, amostra in resultado["amostras"].items():
    plot_normalidade(amostra, variavel)
```

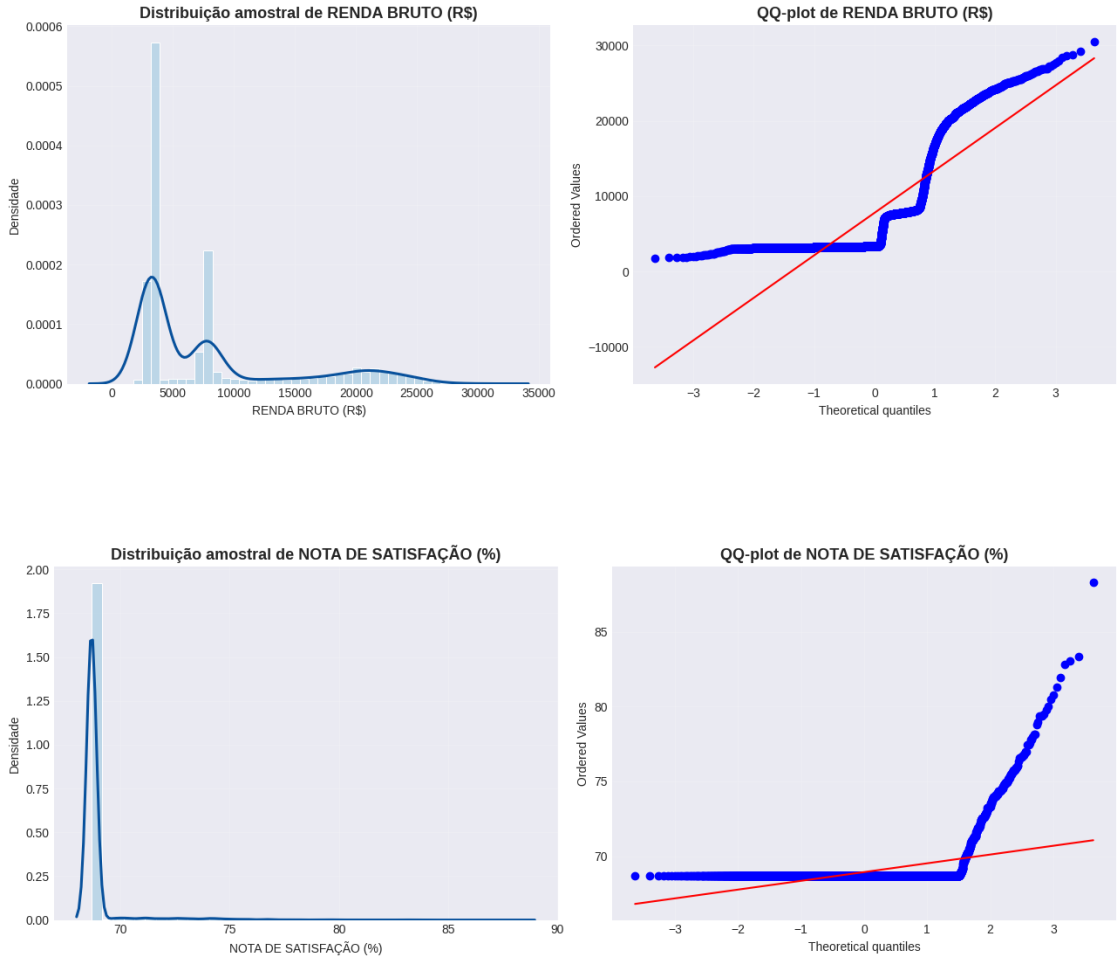

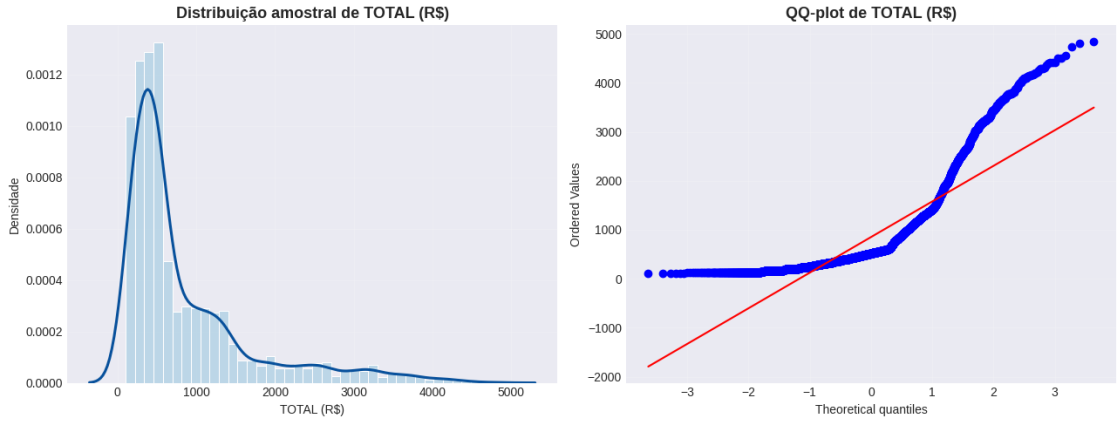

Os resultados do teste de Shapiro-Wilk indicaram rejeição da hipótese de normalidade para as três variáveis analisadas, uma vez que todos os p-valores foram inferiores a `0,05`. Esse resultado também foi confirmado visualmente pelos histogramas e QQ-plots, que evidenciaram assimetria, concentração de valores e desvios importantes em relação ao comportamento esperado sob distribuição normal.

A variável `NOTA DE SATISFAÇÃO (%)` apresentou o caso mais acentuado de não normalidade, com forte concentração no valor `68,68`, correspondente a `93,12%` dos registros, além de elevada assimetria (`5,91`) e curtose (`40,27`). Já as variáveis `RENDA BRUTO (R$)` e `TOTAL (R$)` também apresentaram assimetria positiva (`1,41` e `1,97`, respectivamente), indicando distribuições com cauda à direita e presença de valores extremos.

Dessa forma, conclui-se que as variáveis numéricas analisadas não seguem distribuição normal. Ainda assim, considerando o grande volume amostral e o foco inferencial sobre médias, a continuidade das análises permanece metodologicamente adequada com apoio do Teorema Central do Limite e da validação complementar por bootstrap nas etapas subsequentes.

A1.3.2: Teste de independência Nesta etapa, avalia-se se existe associação estatisticamente significativa entre as variáveis categóricas `REGIÃO` e `TIPO DA CONTA`. Para isso, utiliza-se o teste Qui-Quadrado de independência, complementado pela análise do tamanho de efeito, das frequências esperadas e dos resíduos padronizados.

[30]:
```
# Funções auxiliares

def interpretar_cramers_v(v):
    if np.isnan(v):
        return "N/A"
    if v < 0.05:
        return "Efeito desprezível"
    if v < 0.10:
        return "Efeito fraco"
    if v < 0.30:
        return "Efeito moderado"
```

```
    return "Efeito forte"


def preparar_tabela_contingencia(dados, var1, var2):
    df = dados[[var1, var2]].dropna().copy()
    df[var1] = df[var1].astype(str).str.strip()
    df[var2] = df[var2].astype(str).str.strip()
    df = df[(df[var1] != "") & (df[var2] != "")]

    contingencia = pd.crosstab(df[var1], df[var2])
    return df, contingencia
```

[31]:
```
# Função principal

def AtividadeA1_3_2():
    alpha = 0.05
    var1 = "REGIÃO"
    var2 = "TIPO DA CONTA"

    df, cont = preparar_tabela_contingencia(table, var1, var2)
    n_validos = len(df)

    chi2, p_val, dof, expected = chi2_contingency(cont.values, correction=False)
    decisao = "Rejeita H0" if p_val < alpha else "Não rejeita H0"

    r, c = cont.shape
    k = min(r - 1, c - 1)
    cramers_v = np.sqrt((chi2 / n_validos) / k) if (k > 0 and n_validos > 0)␣
 ↪else np.nan
    interpretacao_v = interpretar_cramers_v(cramers_v)

    expected_df = pd.DataFrame(expected, index=cont.index, columns=cont.columns)
    qtd_expected_lt5 = int((expected_df < 5).sum().sum())
    total_celulas = int(expected_df.size)
    perc_expected_lt5 = (qtd_expected_lt5 / total_celulas) * 100 if␣
 ↪total_celulas > 0 else np.nan

    residuos = (cont - expected_df) / np.sqrt(expected_df)
    residuos = residuos.replace([np.inf, -np.inf], np.nan)

    top_residuos = (
        residuos.abs()
        .stack()
        .sort_values(ascending=False)
        .head(10)
        .reset_index()
    )
```

```
    top_residuos.columns = [var1, var2, "|Resíduo padronizado|"]

    RESULTADOS["A1.3.2"] = {
        "variaveis": (var1, var2),
        "n_validos": int(n_validos),
        "alpha": float(alpha),
        "chi2": float(chi2),
        "p_value": float(p_val),
        "dof": int(dof),
        "decisao": decisao,
        "cramers_v": float(cramers_v) if not np.isnan(cramers_v) else None,
        "interpretacao_cramers_v": interpretacao_v,
        "qtd_expected_lt5": int(qtd_expected_lt5),
        "perc_expected_lt5": float(perc_expected_lt5) if np.
↪isfinite(perc_expected_lt5) else None,
        "contingencia": cont,
        "esperadas": expected_df,
        "residuos_padronizados": residuos,
        "top_residuos": top_residuos,
    }

    print("Teste de independência concluído.")
    print(f"Variáveis analisadas: {var1} e {var2}")
```

[32]:
```
# Execução + tabelas

AtividadeA1_3_2()

resultado = RESULTADOS["A1.3.2"]
```

```
Teste de independência concluído.
Variáveis analisadas: REGIÃO e TIPO DA CONTA
```

[33]:
```
resumo_independencia = pd.DataFrame(
    [
        {
            "Variáveis": f"{resultado['variaveis'][0]} x␣
↪{resultado['variaveis'][1]}",
            "N válidos": resultado["n_validos"],
            "Qui-quadrado": resultado["chi2"],
            "gl": resultado["dof"],
            "p-valor": resultado["p_value"],
            "Decisão": resultado["decisao"],
            "Cramér's V": resultado["cramers_v"],
            "Interpretação": resultado["interpretacao_cramers_v"],
            "% esperado < 5": resultado["perc_expected_lt5"],
        }
```

```
    ]
)

resumo_independencia[["Qui-quadrado", "p-valor", "Cramér's V", "% esperado <␣
↪5"]] = (
    resumo_independencia[["Qui-quadrado", "p-valor", "Cramér's V", "% esperado␣
↪< 5"]].round(4)
)

display(resumo_independencia)
display(resultado["contingencia"])
display(resultado["top_residuos"])
```

```
                Variáveis  N válidos  Qui-quadrado  gl  p-valor  \
0  REGIÃO x TIPO DA CONTA    1120000        7.2988   8   0.5048

          Decisão  Cramér's V       Interpretação  % esperado < 5
0  Não rejeita H0      0.0018  Efeito desprezível             0.0

TIPO DA CONTA  ESSENTIAL   PRIME     VIP
REGIÃO
CENTRO-OESTE       58287   18004   24263
NORDESTE           38854   11840   16107
NORTE              13183    3874    5427
SUDESTE           435957  133807  181229
SUL               103915   32049   43204

         REGIÃO TIPO DA CONTA  |Resíduo padronizado|
0         NORTE         PRIME               2.092502
1         NORTE     ESSENTIAL               1.140632
2           SUL         PRIME               0.687614
3  CENTRO-OESTE         PRIME               0.643782
4      NORDESTE         PRIME               0.580571
5      NORDESTE     ESSENTIAL               0.375126
6  CENTRO-OESTE     ESSENTIAL               0.363518
7           SUL     ESSENTIAL               0.303193
8           SUL           VIP               0.120621
9      NORDESTE           VIP               0.082947
```

[34]:
```
plt.figure(figsize=(12, 5))

sns.heatmap(
    resultado["residuos_padronizados"],
    cmap="coolwarm",
    center=0,
    linewidths=0.6,
    linecolor="white",
    cbar_kws={"label": "Resíduo padronizado"},
```

```
)

plt.title(
    f"Resíduos padronizados: {resultado['variaveis'][0]} x␣
 ↪{resultado['variaveis'][1]}",
    fontsize=14,
    fontweight="bold",
)
plt.xlabel(resultado["variaveis"][1], fontsize=11)
plt.ylabel(resultado["variaveis"][0], fontsize=11)

plt.tight_layout()
sns.despine(left=True, bottom=True)
plt.show()
```

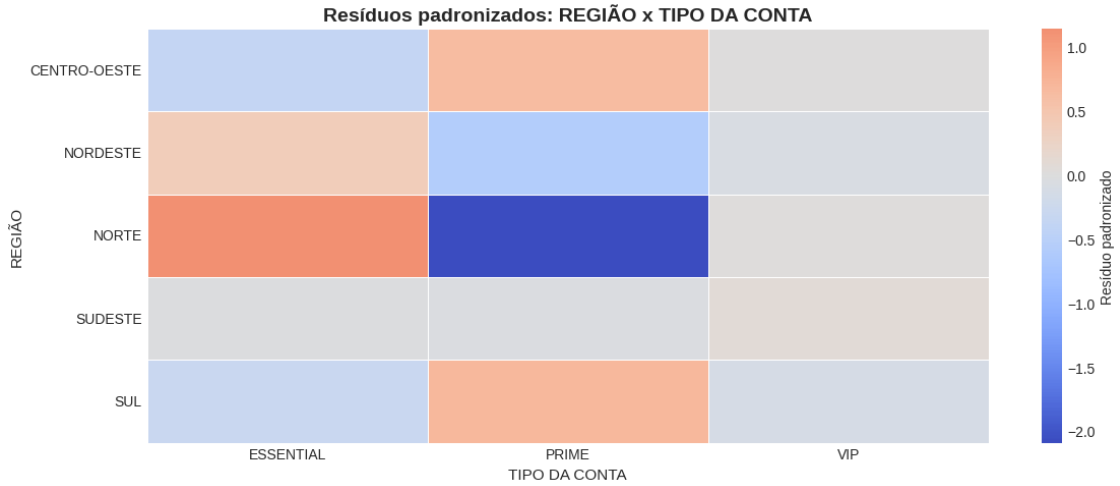

O teste Qui-Quadrado não indicou evidência estatisticamente significativa de associação entre `REGIÃO` e `TIPO DA CONTA`, uma vez que o p-valor obtido foi `0,5048`, superior ao nível de significância de `5%`. Assim, não se rejeita a hipótese nula de independência entre as variáveis analisadas.

Além disso, o valor de `Cramér's V = 0,0018` foi classificado como efeito desprezível, indicando que a relação entre as categorias é praticamente inexistente do ponto de vista prático. Os resíduos padronizados também apresentaram magnitudes baixas, sem desvios expressivos que sugerissem combinações regionais fortemente acima ou abaixo do esperado sob independência.

Dessa forma, conclui-se que, na base analisada, `REGIÃO` e `TIPO DA CONTA` podem ser tratadas como estatisticamente independentes, não havendo evidências de associação relevante entre essas variáveis.

A1.3.3: Teste de distribuição Nesta etapa, avalia-se se a variável `RENDA BRUTO (R$)` apresenta variâncias homogêneas entre os grupos da variável `REGIÃO`. Para isso, utiliza-se o teste de Levene com centro na mediana, complementado por medidas descritivas e visualizações da distribuição por

grupo.

[35]:
```
# Funções auxiliares

def calcular_iqr(serie):
    return float(serie.quantile(0.75) - serie.quantile(0.25))


def preparar_dados_levene(dados, coluna_valor, coluna_grupo):
    df = dados[[coluna_valor, coluna_grupo]].copy()

    df = df.dropna(subset=[coluna_valor, coluna_grupo])
    df[coluna_grupo] = df[coluna_grupo].astype(str).str.strip()
    df = df[df[coluna_grupo] != ""]

    df[coluna_valor] = pd.to_numeric(df[coluna_valor], errors="coerce")
    df = df.dropna(subset=[coluna_valor])
    df = df[df[coluna_valor] >= 0]

    return df
```

[36]:
```
# Função principal

def AtividadeA1_3_3():
    alpha = 0.05
    coluna_valor = "RENDA BRUTO (R$)"
    coluna_grupo = "REGIÃO"
    ordem_preferida = ["NORTE", "NORDESTE", "CENTRO-OESTE", "SUDESTE", "SUL"]

    df = preparar_dados_levene(table, coluna_valor, coluna_grupo)

    n_validos = len(df)
    grupos = df[coluna_grupo].value_counts().sort_values(ascending=False)
    qtd_grupos = len(grupos)

    ordem = [g for g in ordem_preferida if g in grupos.index.tolist()]
    ordem += [g for g in grupos.index.tolist() if g not in ordem]

    resumo = (
        df.groupby(coluna_grupo, as_index=False)[coluna_valor]
        .agg(
            n="count",
            media="mean",
            dp="std",
            mediana="median",
            q1=lambda s: float(s.quantile(0.25)),
            q3=lambda s: float(s.quantile(0.75)),
```

```
            iqr=calcular_iqr,
            minimo="min",
            maximo="max",
        )
    )

    resumo[coluna_grupo] = pd.Categorical(resumo[coluna_grupo],␣
↪categories=ordem, ordered=True)
    resumo = resumo.sort_values(coluna_grupo).reset_index(drop=True)

    series_por_grupo = [
        df.loc[df[coluna_grupo] == g, coluna_valor].values
        for g in ordem
    ]

    estatistica, p_valor = levene(*series_por_grupo, center="median")
    decisao = "Rejeita H0" if p_valor < alpha else "Não rejeita H0"

    RESULTADOS["A1.3.3"] = {
        "coluna_valor": coluna_valor,
        "coluna_grupo": coluna_grupo,
        "n_validos": int(n_validos),
        "qtd_grupos": int(qtd_grupos),
        "ordem_grupos": ordem,
        "n_por_grupo": grupos.to_dict(),
        "estatistica_levene": float(estatistica),
        "p_valor_levene": float(p_valor),
        "alpha": float(alpha),
        "decisao": decisao,
        "resumo_por_grupo": resumo,
        "dados_limpos": df,
    }

    print("Teste de distribuição concluído.")
    print(f"Variável numérica: {coluna_valor}")
    print(f"Variável de agrupamento: {coluna_grupo}")
```

[37]:
```
# Execução + tabelas

AtividadeA1_3_3()

resultado = RESULTADOS["A1.3.3"]
```

```
Teste de distribuição concluído.
Variável numérica: RENDA BRUTO (R$)
Variável de agrupamento: REGIÃO
```

[38]:
```
resumo_levene = pd.DataFrame(
    [
        {
            "Variável": resultado["coluna_valor"],
            "Grupo": resultado["coluna_grupo"],
            "N válidos": resultado["n_validos"],
            "Qtd. grupos": resultado["qtd_grupos"],
            "Estatística de Levene": resultado["estatistica_levene"],
            "p-valor": resultado["p_valor_levene"],
            "Decisão": resultado["decisao"],
        }
    ]
)

resumo_levene[["Estatística de Levene", "p-valor"]] = (
    resumo_levene[["Estatística de Levene", "p-valor"]].round(4)
)

display(resumo_levene)
display(pd.Series(resultado["n_por_grupo"], name="n").to_frame())
display(resultado["resumo_por_grupo"].round(2))
```

```
           Variável   Grupo  N válidos  Qtd. grupos  Estatística de Levene  \
0  RENDA BRUTO (R$)  REGIÃO    1120000            5                 1.6315

   p-valor         Decisão
0   0.1632  Não rejeita H0

                   n
SUDESTE       750993
SUL           179168
CENTRO-OESTE  100554
NORDESTE       66801
NORTE          22484

         REGIÃO       n    media       dp  mediana       q1       q3      iqr  \
0         NORTE   22484  7628.80  6587.61  3358.63  3239.82  8030.18  4790.36
1      NORDESTE   66801  7701.13  6627.12  3364.16  3240.76  8054.54  4813.78
2  CENTRO-OESTE  100554  7737.66  6659.96  3366.24  3240.99  8073.78  4832.79
3       SUDESTE  750993  7721.42  6636.43  3364.99  3240.65  8069.76  4829.11
4           SUL  179168  7737.22  6652.22  3366.80  3240.68  8076.13  4835.45

    minimo    maximo
0  1780.56  29295.96
1  1766.01  31122.07
2  1760.19  30989.75
3  1756.31  33508.25
4  1757.28  32878.75
```

[39]:
```
df_plot = resultado["dados_limpos"].copy()
coluna_valor = resultado["coluna_valor"]
coluna_grupo = resultado["coluna_grupo"]
ordem = resultado["ordem_grupos"]

y_cap = df_plot[coluna_valor].quantile(0.99)
df_plot["_valor_plot"] = df_plot[coluna_valor].clip(upper=y_cap)
```

[42]:
```
cores_regiao = ["#355C7D", "#6C5B7B", "#C06C84", "#F67280", "#F8B195"]

plt.figure(figsize=(12, 5))

sns.boxplot(
    data=df_plot,
    x=coluna_grupo,
    y="_valor_plot",
    order=ordem,
    showfliers=False,
    width=0.58,
    palette=cores_regiao,
    linewidth=1.2,
)

medias = (
    df_plot.groupby(coluna_grupo)["_valor_plot"]
    .mean()
    .reindex(ordem)
)

plt.scatter(
    range(len(ordem)),
    medias.values,
    color="black",
    s=55,
    zorder=5,
    label="Média"
)

plt.title("Distribuição da renda bruta por região", fontsize=15,␣
 ↪fontweight="bold")
plt.xlabel("Região", fontsize=11)
plt.ylabel("Renda bruta (R$)", fontsize=11)
plt.grid(axis="y", alpha=0.18)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
plt.show()
```

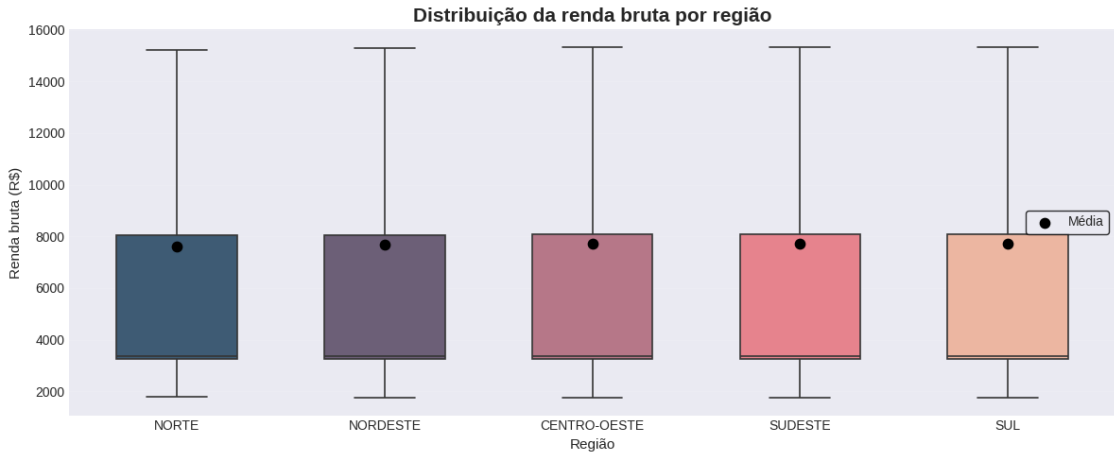

[43]:
```
resumo_plot = resultado["resumo_por_grupo"].copy()

plt.figure(figsize=(12, 5))

bars = plt.bar(
    resumo_plot["REGIÃO"],
    resumo_plot["media"],
    color=["#355C7D", "#6C5B7B", "#C06C84", "#F67280", "#F8B195"],
    alpha=0.90
)

plt.errorbar(
    resumo_plot["REGIÃO"],
    resumo_plot["mediana"],
    yerr=[resumo_plot["mediana"] - resumo_plot["q1"], resumo_plot["q3"] -␣
 ↪resumo_plot["mediana"]],
    fmt="o",
    color="black",
    capsize=6,
    linewidth=1.5,
    label="Mediana e IQR"
)

plt.title("Renda bruta por região: média, mediana e dispersão", fontsize=15,␣
 ↪fontweight="bold")
plt.xlabel("Região", fontsize=11)
plt.ylabel("Renda bruta (R$)", fontsize=11)
plt.grid(axis="y", alpha=0.18)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
```

```
plt.show()
```

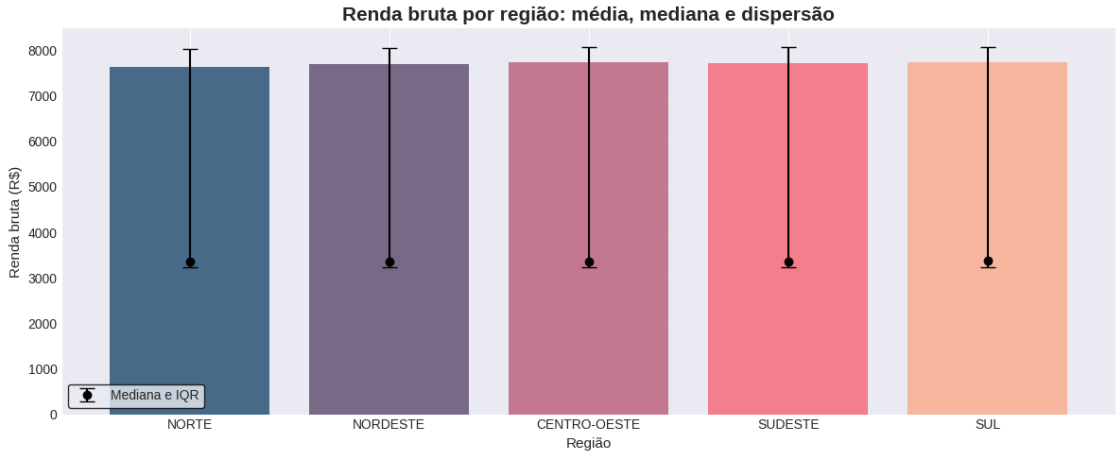

O teste de Levene não indicou evidência estatisticamente significativa para rejeitar a hipótese nula de homogeneidade de variâncias entre os grupos de `REGIÃO`, uma vez que o p-valor obtido foi `0,1632`, superior ao nível de significância de `5%`. Assim, a dispersão da variável `RENDA BRUTO (R$)` pode ser considerada estatisticamente semelhante entre as regiões analisadas.

As estatísticas descritivas por grupo reforçam essa interpretação, pois as médias, medianas e intervalos interquartis apresentaram valores bastante próximos entre si. Embora existam pequenas diferenças numéricas entre as regiões, não se observou evidência de heterocedasticidade relevante do ponto de vista estatístico.

Dessa forma, conclui-se que a suposição de homogeneidade de variâncias é adequada para a variável `RENDA BRUTO (R$)` quando comparada entre os grupos de `REGIÃO`, o que favorece a aplicação de métodos comparativos entre médias que dependem desse pressuposto nas etapas subsequentes.

A1.3.4: Teste das médias amostrais Nesta etapa, compara-se a média da variável `NOTA DE SATISFAÇÃO (%)` entre os grupos de `TIPO DA CONTA`. Para isso, são analisadas as estatísticas descritivas por grupo, a homogeneidade de variâncias e, em seguida, aplicado o teste comparativo mais adequado entre ANOVA clássica, ANOVA de Welch ou alternativa robusta.

[44]:
```
# Funções auxiliares

def preparar_dados_medias(dados, coluna_valor, coluna_grupo):
    df = dados[[coluna_valor, coluna_grupo]].copy()

    df = df.dropna(subset=[coluna_valor, coluna_grupo])
    df[coluna_grupo] = df[coluna_grupo].astype(str).str.strip()
    df = df[df[coluna_grupo] != ""]

    df[coluna_valor] = pd.to_numeric(df[coluna_valor], errors="coerce")
    df = df.dropna(subset=[coluna_valor])
```

```
    return df


def corrigir_holm(p_values):
    p_values = np.asarray(p_values, dtype=float)
    m = len(p_values)
    ordem = np.argsort(p_values)
    ajustados = np.empty(m, dtype=float)

    anterior = 0.0
    for rank, idx in enumerate(ordem):
        valor = min(1.0, (m - rank) * p_values[idx])
        valor = max(valor, anterior)
        ajustados[idx] = valor
        anterior = valor

    return ajustados
```

[45]:
```
# Função principal

def AtividadeA1_3_4():
    alpha = 0.05
    coluna_valor = "NOTA DE SATISFAÇÃO (%)"
    coluna_grupo = "TIPO DA CONTA"

    df = preparar_dados_medias(table, coluna_valor, coluna_grupo)

    n_validos = len(df)
    n_por_grupo = df[coluna_grupo].value_counts()
    grupos_ordem = n_por_grupo.index.tolist()

    resumo = (
        df.groupby(coluna_grupo)[coluna_valor]
        .agg(
            n="count",
            media="mean",
            dp="std",
            mediana="median",
            q1=lambda s: float(s.quantile(0.25)),
            q3=lambda s: float(s.quantile(0.75)),
            minimo="min",
            maximo="max",
        )
        .reset_index()
    )
    resumo["iqr"] = resumo["q3"] - resumo["q1"]
```

```
    resumo = resumo.merge(
        n_por_grupo.rename("n_ref"),
        left_on=coluna_grupo,
        right_index=True,
        how="left",
    )
    resumo = resumo.sort_values("n_ref", ascending=False).
↪drop(columns=["n_ref"])

    arrays = [df.loc[df[coluna_grupo] == g, coluna_valor].values for g in␣
↪grupos_ordem]

    lev_stat, lev_p = levene(*arrays, center="median")
    lev_resultado = "Rejeita H0" if lev_p < alpha else "Não rejeita H0"

    metodo = "ANOVA clássica" if lev_p >= alpha else "ANOVA de Welch"
    estatistica_principal = None
    p_valor_principal = None
    info_teste = {}

    if metodo == "ANOVA clássica":
        f_stat, p_val = f_oneway(*arrays)
        estatistica_principal = float(f_stat)
        p_valor_principal = float(p_val)
        info_teste = {"F": float(f_stat)}
    else:
        try:
            from statsmodels.stats.oneway import anova_oneway

            res = anova_oneway(df[coluna_valor], df[coluna_grupo],␣
↪use_var="unequal")
            estatistica_principal = float(res.statistic)
            p_valor_principal = float(res.pvalue)
            info_teste = {
                "F_welch": float(res.statistic),
                "gl_num": float(res.df_num),
                "gl_den": float(res.df_denom),
            }
        except Exception:
            from scipy.stats import kruskal

            metodo = "Kruskal-Wallis"
            h_stat, p_val = kruskal(*arrays)
            estatistica_principal = float(h_stat)
            p_valor_principal = float(p_val)
            info_teste = {"H": float(h_stat)}
```

```
    decisao_principal = "Rejeita H0" if p_valor_principal < alpha else "Não␣
↪rejeita H0"

    pares = []
    p_brutos = []

    for i in range(len(grupos_ordem)):
        for j in range(i + 1, len(grupos_ordem)):
            g1, g2 = grupos_ordem[i], grupos_ordem[j]
            x1 = df.loc[df[coluna_grupo] == g1, coluna_valor].values
            x2 = df.loc[df[coluna_grupo] == g2, coluna_valor].values

            t_stat, p_val = ttest_ind(x1, x2, equal_var=False)
            pares.append((g1, g2, float(t_stat), float(p_val)))
            p_brutos.append(float(p_val))

    posthoc = pd.DataFrame(pares, columns=["grupo_1", "grupo_2", "t_welch",␣
↪"p_value"])
    posthoc["p_holm"] = corrigir_holm(posthoc["p_value"].values)
    posthoc["diferença_significativa"] = posthoc["p_holm"] < alpha

    eta2_aprox = None
    k = len(grupos_ordem)
    try:
        f_ref = info_teste.get("F", info_teste.get("F_welch"))
        if f_ref is not None:
            eta2_aprox = (f_ref * (k - 1)) / (f_ref * (k - 1) + (n_validos - k))
    except Exception:
        eta2_aprox = None

    RESULTADOS["A1.3.4"] = {
        "coluna_valor": coluna_valor,
        "coluna_grupo": coluna_grupo,
        "n_validos": int(n_validos),
        "n_por_grupo": n_por_grupo.to_dict(),
        "resumo_por_grupo": resumo,
        "levene_stat": float(lev_stat),
        "levene_p_value": float(lev_p),
        "levene_resultado": lev_resultado,
        "metodo": metodo,
        "info_teste": info_teste,
        "estatistica_principal": estatistica_principal,
        "p_value_principal": p_valor_principal,
        "decisao_principal": decisao_principal,
        "eta2_aprox": float(eta2_aprox) if eta2_aprox is not None else None,
        "posthoc_welch_holm": posthoc,
        "dados_limpos": df,
```

```
    }

    print("Teste das médias concluído.")
    print(f"Variável analisada: {coluna_valor}")
    print(f"Grupos analisados: {len(grupos_ordem)}")
```

[46]:
```
# Execução + tabelas

AtividadeA1_3_4()

resultado = RESULTADOS["A1.3.4"]
```

```
Teste das médias concluído.
Variável analisada: NOTA DE SATISFAÇÃO (%)
Grupos analisados: 3
```

[47]:
```
resumo_teste_medias = pd.DataFrame(
    [
        {
            "Variável": resultado["coluna_valor"],
            "Grupo": resultado["coluna_grupo"],
            "N válidos": resultado["n_validos"],
            "Método": resultado["metodo"],
            "Levene p-valor": resultado["levene_p_value"],
            "Teste p-valor": resultado["p_value_principal"],
            "Decisão": resultado["decisao_principal"],
            "Eta² aprox.": resultado["eta2_aprox"],
        }
    ]
)

resumo_teste_medias[["Levene p-valor", "Teste p-valor", "Eta² aprox."]] = (
    resumo_teste_medias[["Levene p-valor", "Teste p-valor", "Eta² aprox."]].
 ↪round(4)
)

display(resumo_teste_medias)
display(resultado["resumo_por_grupo"].round(3))
display(resultado["posthoc_welch_holm"].sort_values("p_holm").round(4))
```

```
                 Variável          Grupo  N válidos          Método  \
0  NOTA DE SATISFAÇÃO (%)  TIPO DA CONTA    1120000  ANOVA de Welch

   Levene p-valor  Teste p-valor     Decisão  Eta² aprox.
0             0.0            0.0  Rejeita H0       0.0545

  TIPO DA CONTA       n   media     dp  mediana     q1      q3  minimo  \
0     ESSENTIAL  650196  68.680  0.000    68.68  68.68  68.680   68.68
```

```
2           VIP  270230  68.681  0.048    68.68  68.68  68.680   68.68
1         PRIME  199574  70.304  2.856    68.68  68.68  71.104   68.68

   maximo    iqr
0  68.680  0.000
2  78.578  0.000
1  92.112  2.424

     grupo_1 grupo_2   t_welch  p_value  p_holm  diferença_significativa
1  ESSENTIAL   PRIME -253.9392      0.0     0.0                     True
2        VIP   PRIME -253.8134      0.0     0.0                     True
0  ESSENTIAL     VIP   -6.9271      0.0     0.0                     True
```

[50]:
```python
resumo_plot = resultado["resumo_por_grupo"].copy()
resumo_plot["se"] = resumo_plot["dp"] / np.sqrt(resumo_plot["n"])
resumo_plot["ic_inf"] = resumo_plot["media"] - 1.96 * resumo_plot["se"]
resumo_plot["ic_sup"] = resumo_plot["media"] + 1.96 * resumo_plot["se"]

plt.figure(figsize=(11, 5))

cores = ["#4C78A8", "#F58518", "#54A24B"]

plt.bar(
    resumo_plot["TIPO DA CONTA"],
    resumo_plot["media"],
    color=cores,
    alpha=0.88,
    width=0.6,
)

plt.errorbar(
    resumo_plot["TIPO DA CONTA"],
    resumo_plot["media"],
    yerr=1.96 * resumo_plot["se"],
    fmt="none",
    ecolor="black",
    elinewidth=1.6,
    capsize=6,
)

for i, valor in enumerate(resumo_plot["media"]):
    plt.text(i, valor + 0.15, f"{valor:.2f}", ha="center", fontsize=10)

plt.title("Média da nota de satisfação por tipo da conta", fontsize=15,␣
 ↪fontweight="bold")
plt.xlabel("Tipo da conta", fontsize=11)
plt.ylabel("Nota de satisfação (%)", fontsize=11)
plt.grid(axis="y", alpha=0.18)
```

```
plt.tight_layout()
sns.despine()
plt.show()
```

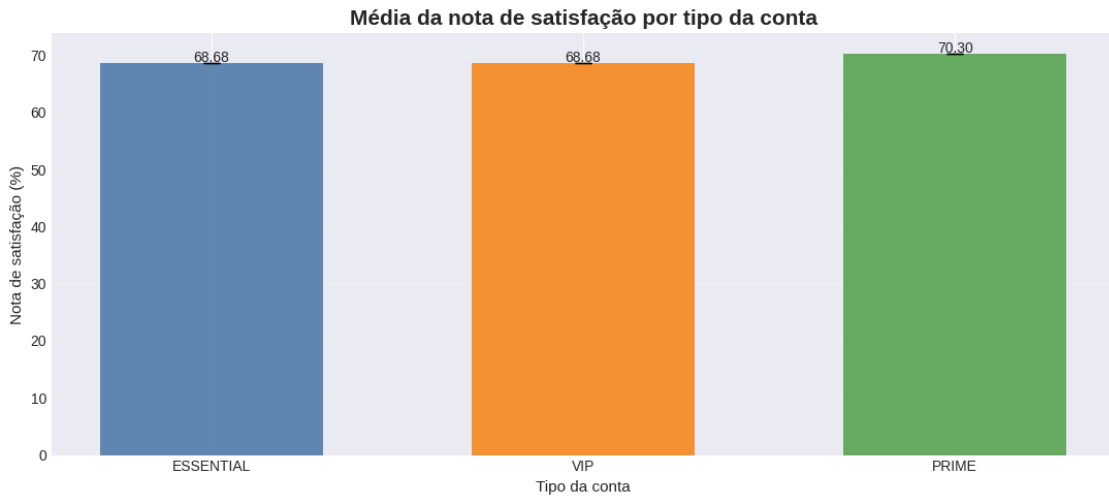

[51]:
```
plt.figure(figsize=(11, 5))

x = np.arange(len(resumo_plot))

plt.bar(
    x,
    resumo_plot["mediana"],
    color=["#355C7D", "#F67280", "#6C5B7B"],
    alpha=0.85,
    width=0.55,
)

plt.errorbar(
    x,
    resumo_plot["mediana"],
    yerr=[resumo_plot["mediana"] - resumo_plot["q1"], resumo_plot["q3"] -␣
 ↪resumo_plot["mediana"]],
    fmt="o",
    color="black",
    capsize=6,
    linewidth=1.5,
    label="Intervalo interquartil",
)

plt.xticks(x, resumo_plot["TIPO DA CONTA"])
```

```
plt.title("Mediana e dispersão da nota de satisfação por tipo da conta",␣
↪fontsize=15, fontweight="bold")
plt.xlabel("Tipo da conta", fontsize=11)
plt.ylabel("Nota de satisfação (%)", fontsize=11)
plt.grid(axis="y", alpha=0.18)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
plt.show()
```

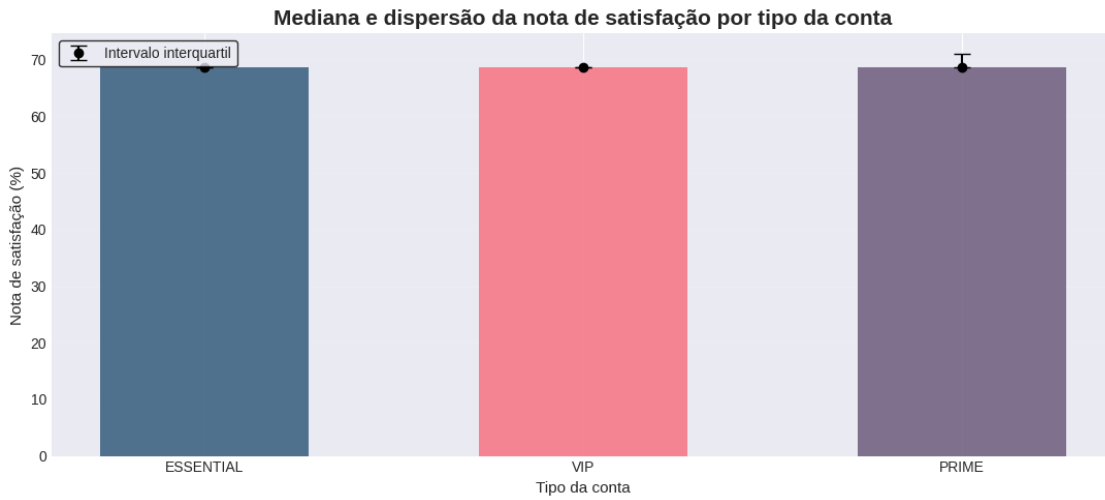

[52]:
```
df_conc = resultado["dados_limpos"].copy()

concentracao = (
    df_conc.assign(igual_6868=df_conc["NOTA DE SATISFAÇÃO (%)"] == 68.68)
    .groupby("TIPO DA CONTA")["igual_6868"]
    .mean()
    .mul(100)
    .reset_index(name="percentual_68_68")
)

plt.figure(figsize=(11, 5))

bars = plt.bar(
    concentracao["TIPO DA CONTA"],
    concentracao["percentual_68_68"],
    color=["#4C78A8", "#F58518", "#54A24B"],
    alpha=0.90,
    width=0.6,
)
```

```
for bar in bars:
    altura = bar.get_height()
    plt.text(
        bar.get_x() + bar.get_width() / 2,
        altura + 0.4,
        f"{altura:.2f}%",
        ha="center",
        fontsize=10,
    )

plt.title("Percentual de registros com nota igual a 68,68 por tipo da conta",␣
 ↪fontsize=15, fontweight="bold")
plt.xlabel("Tipo da conta", fontsize=11)
plt.ylabel("Percentual (%)", fontsize=11)
plt.grid(axis="y", alpha=0.18)
plt.tight_layout()
sns.despine()
plt.show()
```

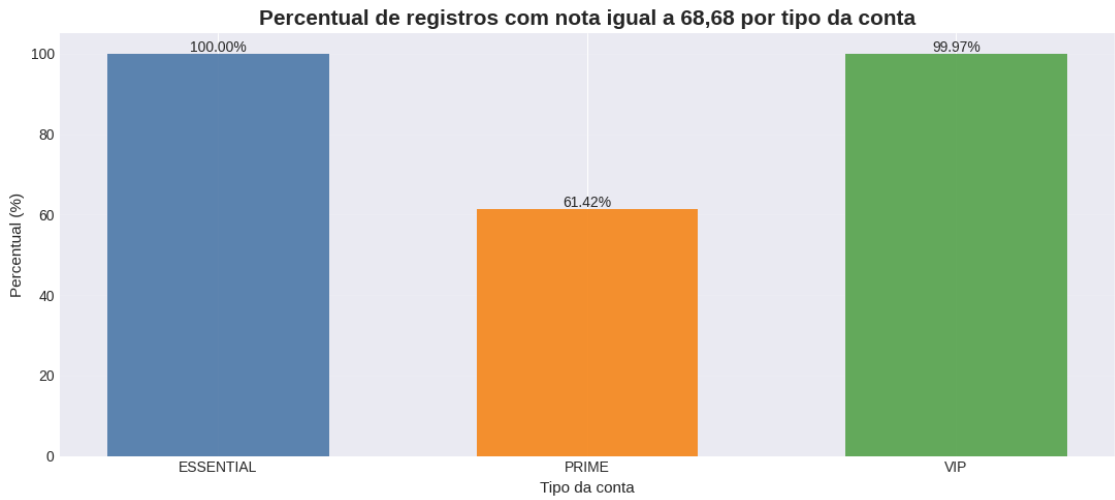

O teste de comparação entre médias indicou evidência estatisticamente significativa de diferença entre os grupos de `TIPO DA CONTA` para a variável `NOTA DE SATISFAÇÃO (%)`, com `p < 0,001`. Como o teste de Levene apontou heterogeneidade de variâncias, adotou-se a `ANOVA de Welch`, procedimento mais adequado para esse cenário. Assim, rejeita-se a hipótese nula de igualdade entre as médias dos grupos.

As estatísticas descritivas mostraram comportamentos distintos entre as categorias. O grupo `ESSENTIAL` apresentou distribuição praticamente constante em `68,68`, enquanto `VIP` manteve valores muito próximos desse nível, com baixa dispersão. Já o grupo `PRIME` apresentou média superior (`70,30`) e variabilidade consideravelmente maior, com intervalo interquartil de `2,42`, indicando distribuição mais espalhada.

Os testes pós-hoc com correção de Holm mostraram que todas as comparações par-a-par foram estatisticamente significativas, evidenciando diferenças entre `ESSENTIAL`, `VIP` e `PRIME`. O tamanho de efeito estimado (² 0,0545) sugere efeito pequeno, porém não desprezível, indicando que o tipo da conta exerce influência real sobre a nota de satisfação, ainda que com magnitude moderada do ponto de vista prático.

Dessa forma, conclui-se que a média da `NOTA DE SATISFAÇÃO (%)` difere entre os tipos de conta, com destaque para o grupo `PRIME`, que apresentou os níveis mais elevados de satisfação e maior dispersão em comparação aos demais grupos.

##Atividade A2 (Link): Estatística descritiva

Nesta etapa são analisadas as variáveis quantitativas e qualitativas com o objetivo de compreender a estrutura da base de dados, identificar padrões, dispersões e possíveis assimetrias.

Essa análise fornece contexto interpretativo para os testes estatísticos realizados anteriormente.

3.0.3 Atividade A2.1: Análise das variáveis quantitativas

Nesta etapa, são analisadas as variáveis quantitativas da base com o objetivo de descrever sua tendência central, dispersão, forma da distribuição e presença de valores extremos. Essa análise oferece suporte à interpretação estatística da base e complementa os testes realizados anteriormente.

[53]:
```
# Funções auxiliares

def calcular_resumo_quantitativo(serie, nome_variavel):
    serie = pd.to_numeric(serie, errors="coerce").dropna()

    if len(serie) == 0:
        return None

    media = float(serie.mean())
    mediana = float(serie.median())
    dp = float(serie.std(ddof=1)) if len(serie) > 1 else 0.0
    minimo = float(serie.min())
    maximo = float(serie.max())

    q1 = float(serie.quantile(0.25))
    q3 = float(serie.quantile(0.75))
    iqr = float(q3 - q1)

    p1 = float(serie.quantile(0.01))
    p5 = float(serie.quantile(0.05))
    p95 = float(serie.quantile(0.95))
    p99 = float(serie.quantile(0.99))

    assimetria = float(serie.skew()) if len(serie) > 2 else np.nan
    curtose = float(serie.kurtosis()) if len(serie) > 3 else np.nan
    cv = float(dp / media) if media != 0 else np.nan
```

```
    lim_inf = float(q1 - 1.5 * iqr)
    lim_sup = float(q3 + 1.5 * iqr)
    outliers_qtd = int(((serie < lim_inf) | (serie > lim_sup)).sum())
    outliers_perc = float((outliers_qtd / len(serie)) * 100)

    return {
        "variavel": nome_variavel,
        "n": int(len(serie)),
        "media": media,
        "mediana": mediana,
        "dp": dp,
        "min": minimo,
        "max": maximo,
        "q1": q1,
        "q3": q3,
        "iqr": iqr,
        "p1": p1,
        "p5": p5,
        "p95": p95,
        "p99": p99,
        "assimetria": assimetria,
        "curtose": curtose,
        "coef_var": cv,
        "lim_inf_iqr": lim_inf,
        "lim_sup_iqr": lim_sup,
        "outliers_qtd": outliers_qtd,
        "outliers_%": outliers_perc,
    }
```

[65]:
```
# Função principal

def AtividadeA2_1():
    df = table.select_dtypes(include=["int64", "float64"]).dropna(axis=1,␣
 ↪how="all").copy()

    resultados = []

    for coluna in df.columns:
        resumo = calcular_resumo_quantitativo(df[coluna], coluna)
        if resumo is not None:
            resultados.append(resumo)

    tabela_resumo = pd.DataFrame(resultados)

    RESULTADOS["A2.1"] = {
        "n_registros": int(len(df)),
        "qtd_variaveis": int(df.shape[1]),
```

```
        "tabela_resumo": tabela_resumo,
    }

    print("Análise das variáveis quantitativas concluída.")
```

[66]:
```
AtividadeA2_1()
resultado = RESULTADOS["A2.1"]
tabela_quant = resultado["tabela_resumo"].copy()
```

```
Análise das variáveis quantitativas concluída.
```

[67]:
```
colunas_visuais = [
    "variavel", "n", "media", "mediana", "dp", "q1", "q3",
    "iqr", "assimetria", "curtose", "coef_var", "outliers_%"
]

tabela_exibicao = tabela_quant[colunas_visuais].copy()
tabela_exibicao[["media", "mediana", "dp", "q1", "q3", "iqr", "assimetria",␣
 ↪"curtose", "coef_var", "outliers_%"]] = (
    tabela_exibicao[["media", "mediana", "dp", "q1", "q3", "iqr", "assimetria",␣
 ↪"curtose", "coef_var", "outliers_%"]].round(4)
)

display(tabela_exibicao)
```

```
                              variavel        n         media       mediana  \
0                          NOTA FISCAL  1120000  5.003551e+06  5.004559e+06
1                          DEPENDENTES  1120000  1.059700e+00  1.000000e+00
2                     RENDA BRUTO (R$)  1120000  7.722335e+03  3.365220e+03
3               NOTA DE SATISFAÇÃO (%)  1120000  6.896950e+01  6.868000e+01
4                       MEAN: alcohol  1120000  1.300160e+01  1.300150e+01
5                    MEAN: malic_acid  1120000  2.335300e+00  2.336400e+00
6                           MEAN: ash  1120000  2.366500e+00  2.366600e+00
7              MEAN: alcalinity_of_ash  1120000  1.949480e+01  1.949560e+01
8                     MEAN: magnesium  1120000  9.976070e+01  9.975260e+01
9                 MEAN: total_phenols  1120000  2.295800e+00  2.296400e+00
10                   MEAN: flavanoids  1120000  2.029300e+00  2.029400e+00
11          MEAN: nonflavanoid_phenols  1120000  3.619000e-01  3.619000e-01
12               MEAN: proanthocyanins  1120000  1.591000e+00  1.591100e+00
13               MEAN: color_intensity  1120000  5.058400e+00  5.058800e+00
14                           MEAN: hue  1120000  9.574000e-01  9.574000e-01
15  MEAN: od280/od315_of_diluted_wines  1120000  2.612400e+00  2.611700e+00
16                       MEAN: proline  1120000  7.469062e+02  7.473684e+02
17                          TOTAL (R$)  1120000  8.511867e+02  5.109600e+02

              dp            q1            q3           iqr  assimetria  \
0   2.309364e+06  3.004136e+06  7.004358e+06  4.000222e+06     -0.0006
```

```
1   9.570000e-01  0.000000e+00  1.000000e+00  1.000000e+00      1.1788
2   6.639554e+03  3.240670e+03  8.069252e+03  4.828583e+03      1.4110
3   1.356600e+00  6.868000e+01  6.868000e+01  0.000000e+00      5.9103
4   8.096000e-01  1.245510e+01  1.354820e+01  1.093100e+00     -0.0002
5   1.114100e+00  1.584800e+00  3.086200e+00  1.501300e+00     -0.0044
6   2.737000e-01  2.181800e+00  2.550900e+00  3.691000e-01     -0.0030
7   3.334300e+00  1.724720e+01  2.174080e+01  4.493600e+00     -0.0008
8   1.424360e+01  9.015000e+01  1.093708e+02  1.922090e+01      0.0013
9   6.242000e-01  1.875000e+00  2.717600e+00  8.426000e-01     -0.0051
10  9.964000e-01  1.357100e+00  2.700500e+00  1.343400e+00      0.0026
11  1.240000e-01  2.784000e-01  4.456000e-01  1.672000e-01      0.0018
12  5.707000e-01  1.205900e+00  1.977100e+00  7.711000e-01     -0.0023
13  2.313400e+00  3.498100e+00  6.619800e+00  3.121700e+00      0.0004
14  2.279000e-01  8.038000e-01  1.111200e+00  3.075000e-01     -0.0054
15  7.082000e-01  2.135000e+00  3.089900e+00  9.549000e-01      0.0008
16  3.137369e+02  5.353219e+02  9.589491e+02  4.236272e+02     -0.0071
17  8.520839e+02  3.239200e+02  1.068840e+03  7.449200e+02      1.9738

    curtose  coef_var  outliers_%
0   -1.2008    0.4615      0.0000
1    1.3475    0.9030      9.9892
2    0.6259    0.8598     17.3903
3   40.2667    0.0197      6.8826
4   -0.0041    0.0623      0.6843
5    0.0025    0.4771      0.7065
6    0.0047    0.1157      0.7028
7    0.0003    0.1710      0.7038
8   -0.0025    0.1428      0.6879
9    0.0054    0.2719      0.7040
10   0.0013    0.4910      0.7036
11   0.0001    0.3426      0.7015
12  -0.0041    0.3587      0.6871
13   0.0043    0.4573      0.7051
14  -0.0011    0.2380      0.6943
15  -0.0002    0.2711      0.7033
16  -0.0022    0.4200      0.6876
17   3.5316    1.0011      9.5449
```

[69]:
```
maior_cv = tabela_quant.sort_values("coef_var", ascending=False).head(5)
maior_outliers = tabela_quant.sort_values("outliers_%", ascending=False).head(5)
maior_assimetria = tabela_quant.reindex(
    tabela_quant["assimetria"].abs().sort_values(ascending=False).index
).head(5)
display(maior_cv[["variavel", "coef_var"]].round(4))
display(maior_outliers[["variavel", "outliers_%"]].round(4))
display(maior_assimetria[["variavel", "assimetria"]].round(4))
```

```
            variavel  coef_var
```

```
17        TOTAL (R$)    1.0011
1        DEPENDENTES    0.9030
2   RENDA BRUTO (R$)    0.8598
10  MEAN: flavanoids    0.4910
5   MEAN: malic_acid    0.4771

                  variavel  outliers_%
2         RENDA BRUTO (R$)     17.3903
1              DEPENDENTES      9.9892
17              TOTAL (R$)      9.5449
3   NOTA DE SATISFAÇÃO (%)      6.8826
5         MEAN: malic_acid      0.7065

                  variavel  assimetria
3   NOTA DE SATISFAÇÃO (%)      5.9103
17              TOTAL (R$)      1.9738
2         RENDA BRUTO (R$)      1.4110
1              DEPENDENTES      1.1788
16           MEAN: proline     -0.0071
```

[70]:
```
serie = table["RENDA BRUTO (R$)"].dropna()
cap = serie.quantile(0.99)
serie_plot = serie.clip(upper=cap)

q1 = serie.quantile(0.25)
mediana = serie.median()
q3 = serie.quantile(0.75)

plt.figure(figsize=(11, 5))

sns.histplot(
    serie_plot,
    bins=40,
    stat="density",
    color="#7FB3D5",
    edgecolor="white",
    alpha=0.75,
)

sns.kdeplot(
    serie_plot,
    color="#0B5FA5",
    linewidth=2.4,
)

plt.axvline(q1, color="#F4A261", linestyle="--", linewidth=2, label="Q1")
plt.axvline(mediana, color="#E76F51", linestyle="-", linewidth=2.2,␣
 ↪label="Mediana")
```

```
plt.axvline(q3, color="#2A9D8F", linestyle="--", linewidth=2, label="Q3")

plt.title("Distribuição da renda bruta", fontsize=15, fontweight="bold")
plt.xlabel("RENDA BRUTO (R$)", fontsize=11)
plt.ylabel("Densidade", fontsize=11)
plt.grid(alpha=0.18)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
plt.show()
```

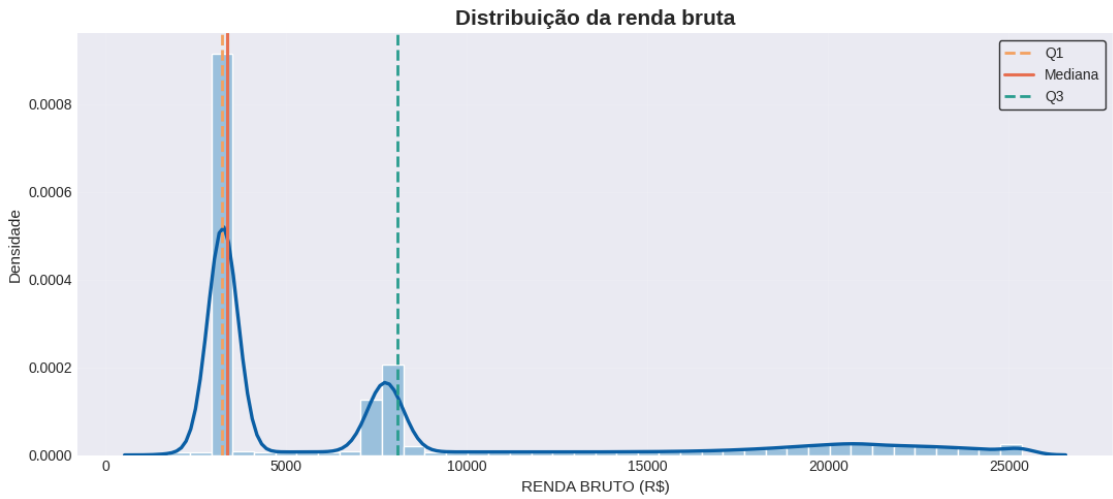

[71]:
```
serie = table["NOTA DE SATISFAÇÃO (%)"].dropna()
top_valores = (serie.value_counts(normalize=True).head(8) * 100).sort_values()

plt.figure(figsize=(10, 5))

bars = plt.barh(
    top_valores.index.astype(str),
    top_valores.values,
    color=sns.color_palette("Blues", len(top_valores))
)

for bar in bars:
    largura = bar.get_width()
    plt.text(
        largura + 0.15,
        bar.get_y() + bar.get_height() / 2,
        f"{largura:.2f}%",
        va="center",
        fontsize=10,
```

```
    )

plt.title("Valores mais frequentes da nota de satisfação", fontsize=15,␣
 ↪fontweight="bold")
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Nota", fontsize=11)
plt.grid(axis="x", alpha=0.18)
plt.tight_layout()
sns.despine()
plt.show()
```

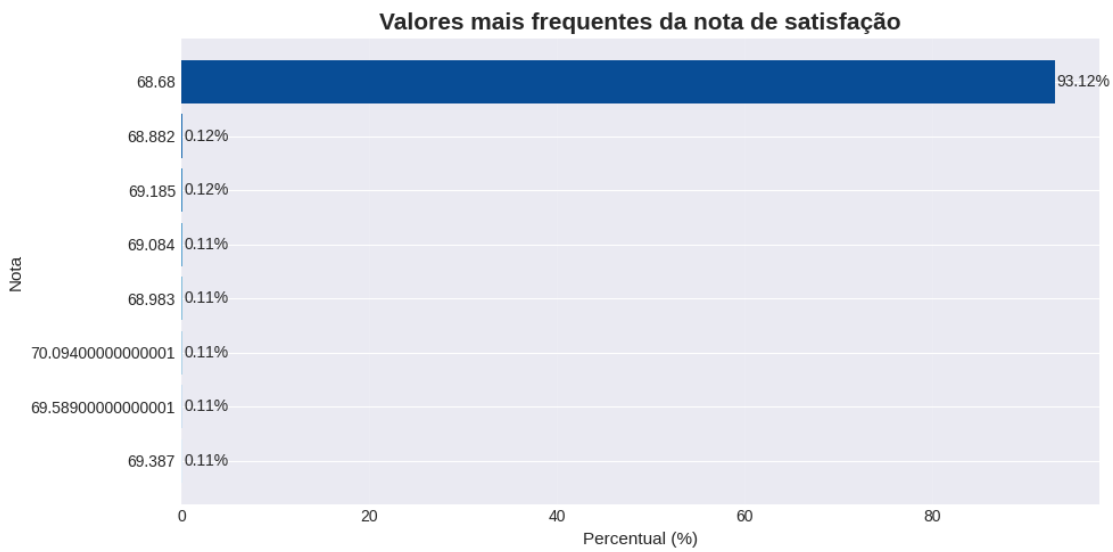

[72]:
```
serie = table["TOTAL (R$)"].dropna()
cap = serie.quantile(0.99)
serie_plot = serie.clip(upper=cap)

q1 = serie.quantile(0.25)
mediana = serie.median()
q3 = serie.quantile(0.75)

plt.figure(figsize=(11, 5))

sns.histplot(
    serie_plot,
    bins=40,
    stat="density",
    color="#A8D5BA",
    edgecolor="white",
    alpha=0.75,
```

```
)

sns.kdeplot(
    serie_plot,
    color="#2E8B57",
    linewidth=2.4,
)

plt.axvline(q1, color="#F4A261", linestyle="--", linewidth=2, label="Q1")
plt.axvline(mediana, color="#E76F51", linestyle="-", linewidth=2.2,␣
 ↪label="Mediana")
plt.axvline(q3, color="#2A9D8F", linestyle="--", linewidth=2, label="Q3")

plt.title("Distribuição do valor total", fontsize=15, fontweight="bold")
plt.xlabel("TOTAL (R$)", fontsize=11)
plt.ylabel("Densidade", fontsize=11)
plt.grid(alpha=0.18)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
plt.show()
```

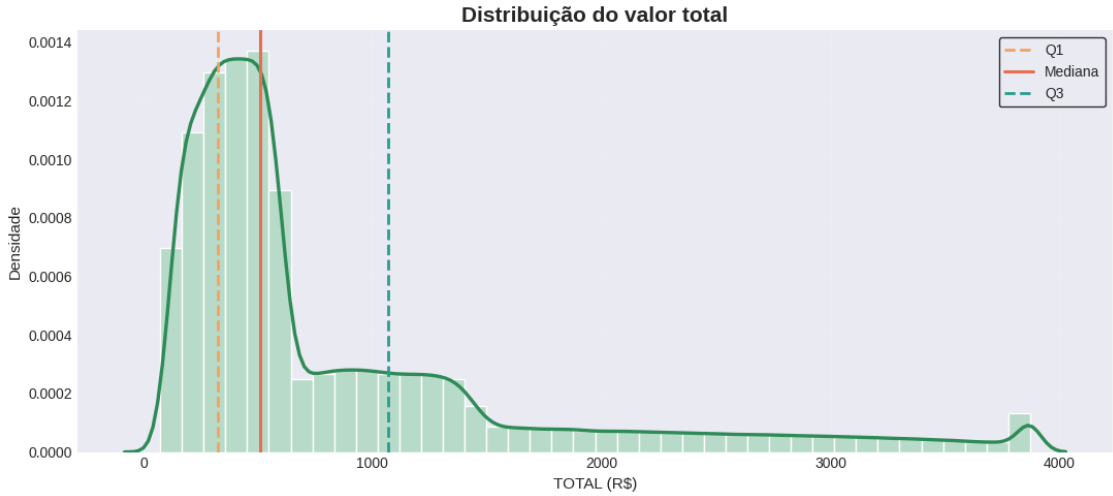

A análise das variáveis quantitativas evidenciou comportamentos distintos em termos de dispersão, concentração e assimetria entre os indicadores numéricos da base. Em relação à variabilidade relativa, destacou-se a variável `TOTAL (R$)`, que apresentou o maior coeficiente de variação (`1,0011`), indicando elevada heterogeneidade proporcional em relação à média.

No critério de outliers pelo intervalo interquartil, a variável `RENDA BRUTO (R$)` apresentou a maior incidência de valores extremos (`17,39%`), seguida por `DEPENDENTES` (`9,99%`) e `TOTAL (R$)` (`9,54%`). Esse resultado sugere a presença de caudas longas e reforça a necessidade de cautela na interpretação de medidas como média e desvio-padrão, especialmente nas variáveis de natureza monetária.

Quanto à forma da distribuição, a variável `NOTA DE SATISFAÇÃO (%)` apresentou a maior assimetria (`5,9103`), refletindo forte concentração em torno do valor `68,68`, que corresponde a `93,12%` dos registros. As variáveis `TOTAL (R$)` (`1,9738`) e `RENDA BRUTO (R$)` (`1,4110`) também exibiram assimetria positiva relevante, indicando distribuições com cauda à direita e afastamento da simetria.

De modo geral, os resultados descritivos e visuais mostram que as variáveis quantitativas não apresentam comportamento homogêneo, havendo diferenças importantes de dispersão, presença de extremos e concentração de valores. Esse diagnóstico complementa as análises anteriores e fornece base interpretativa importante para a escolha e a leitura dos testes estatísticos aplicados ao longo do estudo.

3.0.4 Atividade A2.2: Análise das variáveis qualitativas

Nesta etapa, são analisadas as variáveis qualitativas da base com o objetivo de identificar frequência das categorias, concentração, cardinalidade e possíveis padrões de distribuição. Essa análise complementa a leitura estatística da base e contribui para a compreensão do perfil dos registros observados.

[73]:
```
def resumir_variavel_qualitativa(serie, n_total, top_n=10):
    serie = serie.astype("string").str.strip()

    missing_mask = serie.isna() | (serie == "") | (serie.str.lower() == "nan")
    missing_qtd = int(missing_mask.sum())
    missing_pct = float((missing_qtd / n_total) * 100)

    serie_valid = serie[~missing_mask]
    n_validos = int(len(serie_valid))

    if n_validos == 0:
        return {
            "resumo": {
                "n_total": int(n_total),
                "n_validos": 0,
                "missing_qtd": missing_qtd,
                "missing_%": missing_pct,
                "categorias_unicas": 0,
                "moda": None,
                "moda_qtd": 0,
                "moda_%_validos": 0.0,
                "top1_%_validos": 0.0,
                "top3_%_validos": 0.0,
                "top5_%_validos": 0.0,
                "diversidade": "sem dados",
            },
            "top_table": pd.DataFrame(columns=["categoria", "freq_abs",␣
↪"freq_%"]),
        }
```

```
    freq_abs = serie_valid.value_counts()
    freq_rel = (freq_abs / n_validos) * 100

    moda = str(freq_abs.index[0])
    moda_qtd = int(freq_abs.iloc[0])
    moda_pct = float(freq_rel.iloc[0])

    top1 = float(freq_rel.iloc[:1].sum())
    top3 = float(freq_rel.iloc[:3].sum())
    top5 = float(freq_rel.iloc[:5].sum())

    if top1 >= 70:
        diversidade = "alta concentração"
    elif top1 >= 40:
        diversidade = "concentração moderada"
    else:
        diversidade = "distribuição mais equilibrada"

    top_table = pd.DataFrame({
        "categoria": freq_abs.index.astype("string")[:top_n],
        "freq_abs": freq_abs.values[:top_n],
        "freq_%": freq_rel.values[:top_n],
    })

    resumo = {
        "n_total": int(n_total),
        "n_validos": n_validos,
        "missing_qtd": missing_qtd,
        "missing_%": missing_pct,
        "categorias_unicas": int(freq_abs.shape[0]),
        "moda": moda,
        "moda_qtd": moda_qtd,
        "moda_%_validos": moda_pct,
        "top1_%_validos": top1,
        "top3_%_validos": top3,
        "top5_%_validos": top5,
        "diversidade": diversidade,
    }

    return {"resumo": resumo, "top_table": top_table}
```

[74]:
```
def AtividadeA2_2():
    df = table.copy()
    n_total = int(len(df))

    cat_df = df.select_dtypes(include=["object", "category", "bool"]).copy()
```

```
heuristicas = []
for coluna in df.columns:
    if coluna in cat_df.columns:
        continue

    if pd.api.types.is_integer_dtype(df[coluna]) or pd.api.types.
↪is_float_dtype(df[coluna]):
        serie_tmp = df[coluna].dropna()
        if len(serie_tmp) == 0:
            continue

        nunique = int(serie_tmp.nunique())
        if 1 < nunique <= 12:
            heuristicas.append(coluna)

for coluna in heuristicas:
    cat_df[coluna] = df[coluna].astype("Int64").astype("string")

resultados = {}
linhas_resumo = []

for coluna in cat_df.columns:
    saida = resumir_variavel_qualitativa(cat_df[coluna], n_total=n_total,␣
↪top_n=10)

    resultados[coluna] = {
        "resumo": saida["resumo"],
        "top_categorias": saida["top_table"],
    }

    linhas_resumo.append({
        "variavel": coluna,
        **saida["resumo"],
    })

tabela_resumo = pd.DataFrame(linhas_resumo)

RESULTADOS["A2.2"] = {
    "variaveis": list(cat_df.columns),
    "variaveis_heuristicas": heuristicas,
    "resumo_por_variavel": resultados,
    "tabela_resumo": tabela_resumo,
}

print("Análise das variáveis qualitativas concluída.")
print(f"Registros analisados: {n_total:,}")
print(f"Variáveis qualitativas: {cat_df.shape[1]}")
```

[75]:
```
AtividadeA2_2()

resultado = RESULTADOS["A2.2"]
tabela_qualitativas = resultado["tabela_resumo"].copy()
```

```
Análise das variáveis qualitativas concluída.
Registros analisados: 1,120,000
Variáveis qualitativas: 6
```

[82]:
```
tabela_qualitativas = resultado["tabela_resumo"].copy()

colunas_visuais = [
    "variavel",
    "missing_%",
    "categorias_unicas",
    "moda",
    "moda_%_validos",
    "top1_%_validos",
    "top3_%_validos",
    "top5_%_validos",
    "diversidade",
]

tabela_exibicao = tabela_qualitativas[colunas_visuais].copy()
tabela_exibicao[["missing_%", "moda_%_validos", "top1_%_validos",␣
 ↪"top3_%_validos", "top5_%_validos"]] = (
    tabela_exibicao[["missing_%", "moda_%_validos", "top1_%_validos",␣
 ↪"top3_%_validos", "top5_%_validos"]].round(2)
)

display(tabela_exibicao)
```

```
             variavel  missing_%  categorias_unicas  \
0              REGIÃO        0.0                  5
1                SEXO        0.0                  2
2        ESTADO CIVIL        0.0                  3
3  OPINIÃO DO CLIENTE        0.0                 25
4       TIPO DA CONTA        0.0                  3
5         DEPENDENTES        0.0                  5

                                moda  moda_%_validos  top1_%_validos  \
0                            SUDESTE           67.05           67.05
1                          MASCULINO           86.95           86.95
2                             CASADO           54.98           54.98
3  Entrega foi boa e rápida na UVVine           15.43           15.43
4                          ESSENTIAL           58.05           58.05
5                                  1           52.99           52.99
```

```
   top3_%_validos  top5_%_validos                    diversidade
0           92.03           100.0          concentração moderada
1          100.00           100.0              alta concentração
2          100.00           100.0          concentração moderada
3           46.25            77.0  distribuição mais equilibrada
4          100.00           100.0          concentração moderada
5           90.01           100.0          concentração moderada
```

[83]:
```
top_table = resultado["resumo_por_variavel"]["REGIÃO"]["top_categorias"].copy()

plt.figure(figsize=(10, 5))

bars = plt.barh(
    top_table["categoria"],
    top_table["freq_%"],
    color=sns.color_palette("Blues", len(top_table)),
    edgecolor="white",
    linewidth=0.8,
)

for bar, valor in zip(bars, top_table["freq_%"]):
    plt.text(
        bar.get_width() + 0.25,
        bar.get_y() + bar.get_height() / 2,
        f"{valor:.2f}%",
        va="center",
        fontsize=10,
    )

plt.title("Distribuição das categorias de REGIÃO", fontsize=14,␣
 ↪fontweight="bold")
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Categoria", fontsize=11)
plt.grid(axis="x", alpha=0.18)
plt.tight_layout()
sns.despine()
plt.show()
```

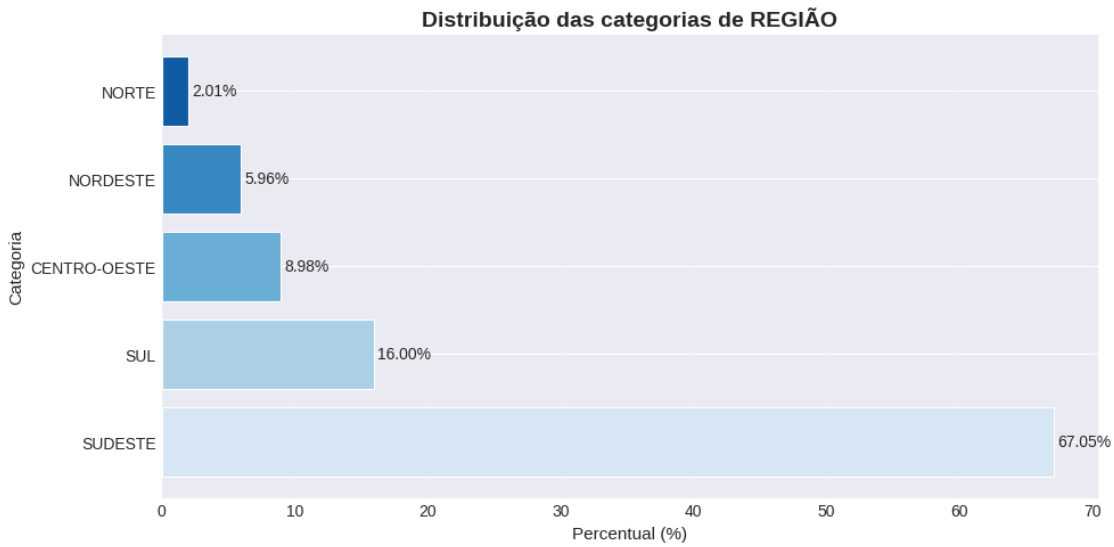

[84]:
```
top_table = resultado["resumo_por_variavel"]["SEXO"]["top_categorias"].copy()

plt.figure(figsize=(10, 4.8))

bars = plt.barh(
    top_table["categoria"],
    top_table["freq_%"],
    color=sns.color_palette("Blues", len(top_table)),
    edgecolor="white",
    linewidth=0.8,
)

for bar, valor in zip(bars, top_table["freq_%"]):
    plt.text(
        bar.get_width() + 0.25,
        bar.get_y() + bar.get_height() / 2,
        f"{valor:.2f}%",
        va="center",
        fontsize=10,
    )

plt.title("Distribuição das categorias de SEXO", fontsize=14, fontweight="bold")
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Categoria", fontsize=11)
plt.grid(axis="x", alpha=0.18)
plt.tight_layout()
sns.despine()
plt.show()
```

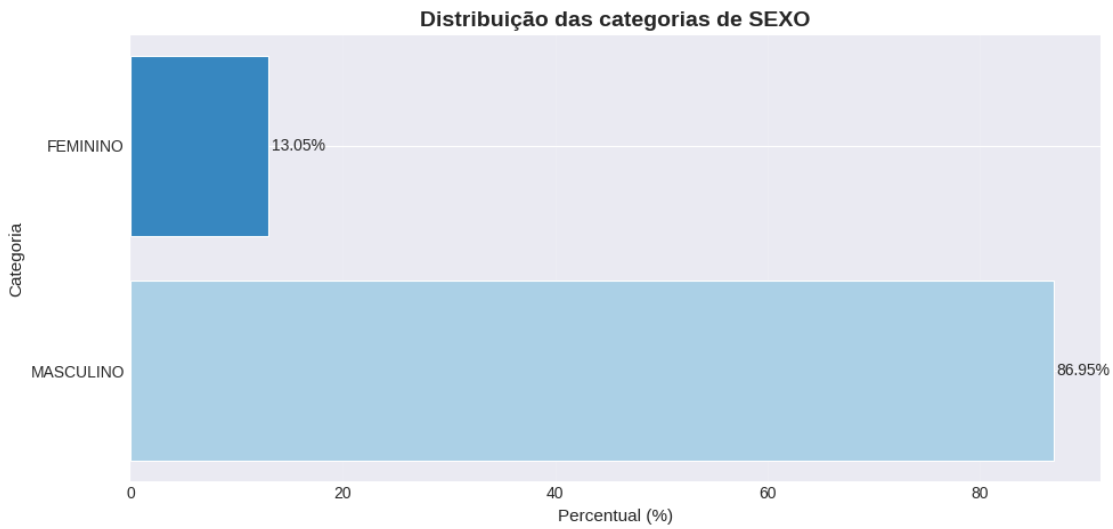

[85]:
```
top_table = resultado["resumo_por_variavel"]["ESTADO CIVIL"]["top_categorias"].
 ↪copy()

plt.figure(figsize=(10, 5))

bars = plt.barh(
    top_table["categoria"],
    top_table["freq_%"],
    color=sns.color_palette("Blues", len(top_table)),
    edgecolor="white",
    linewidth=0.8,
)

for bar, valor in zip(bars, top_table["freq_%"]):
    plt.text(
        bar.get_width() + 0.25,
        bar.get_y() + bar.get_height() / 2,
        f"{valor:.2f}%",
        va="center",
        fontsize=10,
    )

plt.title("Distribuição das categorias de ESTADO CIVIL", fontsize=14,␣
 ↪fontweight="bold")
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Categoria", fontsize=11)
plt.grid(axis="x", alpha=0.18)
plt.tight_layout()
sns.despine()
```

```
plt.show()
```

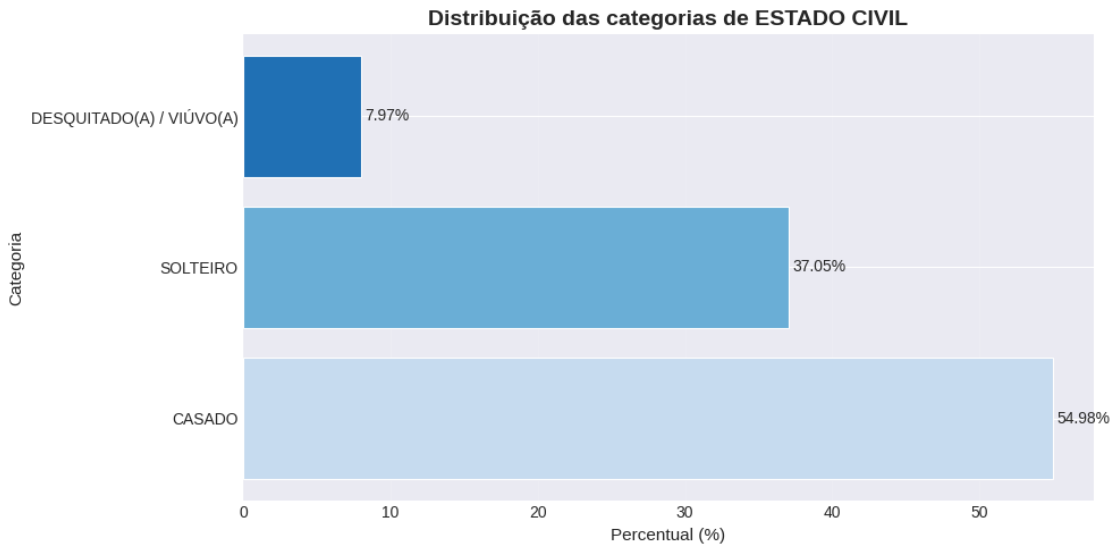

[86]:
```
top_table = resultado["resumo_por_variavel"]["TIPO DA CONTA"]["top_categorias"].
 ↪copy()

plt.figure(figsize=(10, 5))

bars = plt.barh(
    top_table["categoria"],
    top_table["freq_%"],
    color=sns.color_palette("Blues", len(top_table)),
    edgecolor="white",
    linewidth=0.8,
)

for bar, valor in zip(bars, top_table["freq_%"]):
    plt.text(
        bar.get_width() + 0.25,
        bar.get_y() + bar.get_height() / 2,
        f"{valor:.2f}%",
        va="center",
        fontsize=10,
    )

plt.title("Distribuição das categorias de TIPO DA CONTA", fontsize=14,␣
 ↪fontweight="bold")
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Categoria", fontsize=11)
```

```
plt.grid(axis="x", alpha=0.18)
plt.tight_layout()
sns.despine()
plt.show()
```

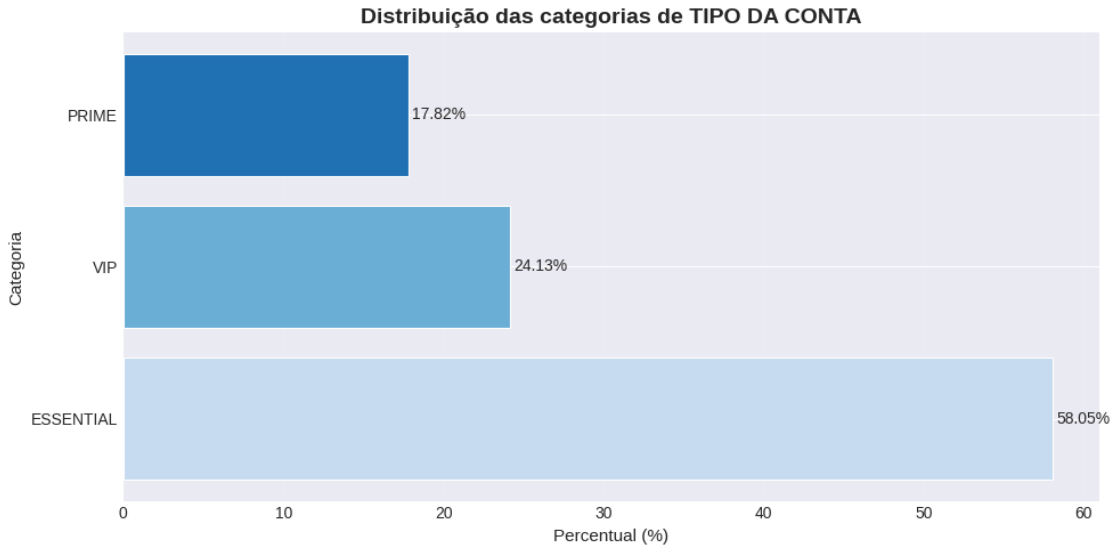

[87]:
```
top_table = resultado["resumo_por_variavel"]["DEPENDENTES"]["top_categorias"].
 ↪copy()

plt.figure(figsize=(10, 5))

bars = plt.barh(
    top_table["categoria"].astype(str),
    top_table["freq_%"],
    color=sns.color_palette("Blues", len(top_table)),
    edgecolor="white",
    linewidth=0.8,
)

for bar, valor in zip(bars, top_table["freq_%"]):
    plt.text(
        bar.get_width() + 0.25,
        bar.get_y() + bar.get_height() / 2,
        f"{valor:.2f}%",
        va="center",
        fontsize=10,
    )
```

```
plt.title("Distribuição das categorias de DEPENDENTES", fontsize=14,␣
↪fontweight="bold")
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Categoria", fontsize=11)
plt.grid(axis="x", alpha=0.18)
plt.tight_layout()
sns.despine()
plt.show()
```

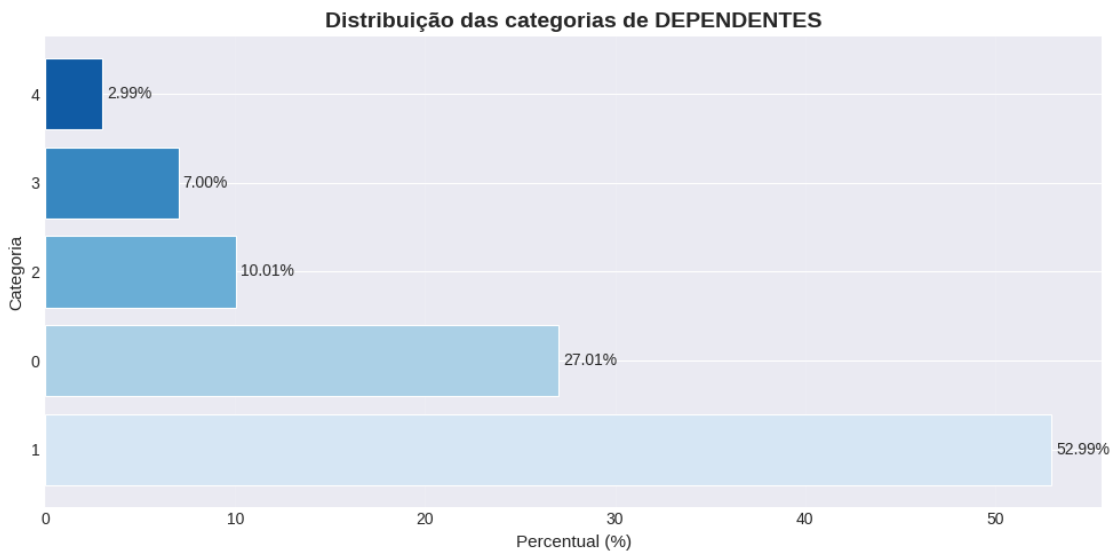

[88]:
```
top_table = resultado["resumo_por_variavel"]["OPINIÃO DO␣
↪CLIENTE"]["top_categorias"].copy().head(8)
top_table["categoria_curta"] = top_table["categoria"].str.slice(0, 42) + "..."

plt.figure(figsize=(11, 6))

bars = plt.barh(
    top_table["categoria_curta"],
    top_table["freq_%"],
    color=sns.color_palette("crest", len(top_table)),
    edgecolor="white",
    linewidth=0.8,
)

for bar, valor in zip(bars, top_table["freq_%"]):
    plt.text(
        bar.get_width() + 0.2,
        bar.get_y() + bar.get_height() / 2,
        f"{valor:.2f}%",
```

```
        va="center",
        fontsize=10,
    )

plt.title("Principais categorias de OPINIÃO DO CLIENTE", fontsize=14,␣
 ↪fontweight="bold")
plt.xlabel("Percentual (%)", fontsize=11)
plt.ylabel("Categoria", fontsize=11)
plt.grid(axis="x", alpha=0.18)
plt.tight_layout()
sns.despine()
plt.show()
```

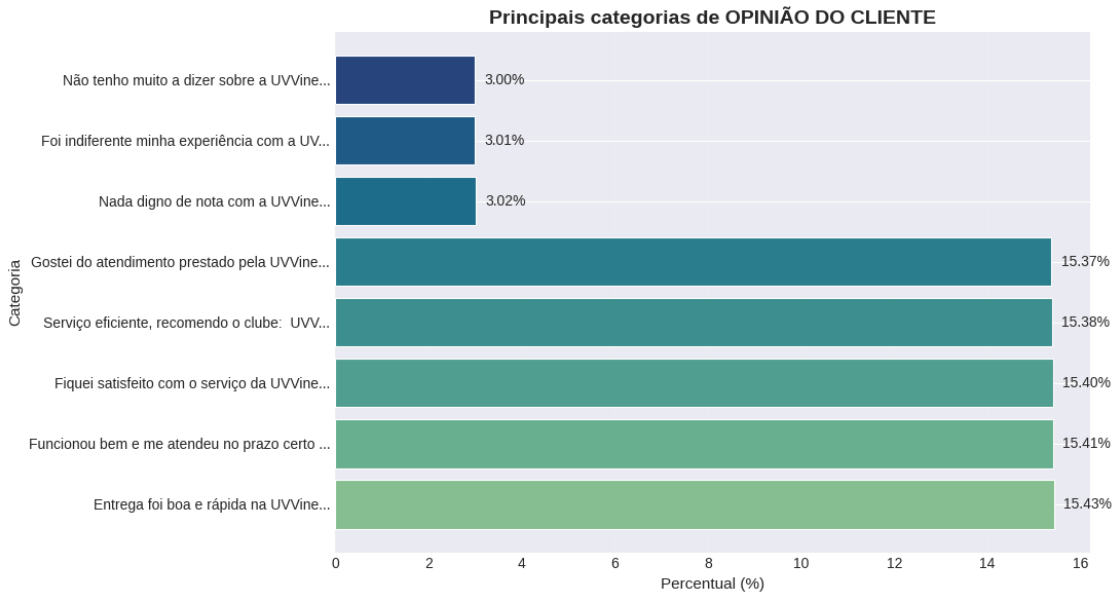

A análise das variáveis qualitativas mostrou ausência de valores ausentes nas categorias avaliadas, o que favorece a consistência descritiva desta etapa. Em termos de concentração, a variável `SEXO` apresentou o padrão mais dominante, com `86,95%` dos registros classificados como `MASCULINO`, caracterizando alta concentração e baixa variabilidade categórica.

As variáveis `REGIÃO`, `ESTADO CIVIL`, `TIPO DA CONTA` e `DEPENDENTES` apresentaram concentração moderada, com predominância clara de uma categoria principal. Destacam-se, respectivamente, `SUDESTE` em `REGIÃO` (`67,05%`), `CASADO` em `ESTADO CIVIL` (`54,98%`), `ESSENTIAL` em `TIPO DA CONTA` (`58,05%`) e `1` em `DEPENDENTES` (`52,99%`).

Por outro lado, a variável `OPINIÃO DO CLIENTE` apresentou a maior diversidade categórica, com `25` categorias distintas e categoria modal de `15,43%`, o que indica distribuição mais equilibrada em comparação às demais variáveis qualitativas. Ainda assim, as cinco categorias mais frequentes concentram `77,00%` das respostas, sugerindo diversidade com predominância parcial de alguns padrões de opinião.

De modo geral, os resultados indicam que as variáveis qualitativas da base combinam estruturas mais concentradas, como `SEXO`, com variáveis mais diversificadas, como `OPINIÃO DO CLIENTE`. Esse diagnóstico contribui para caracterizar o perfil dos registros e complementa a interpretação estatística das etapas subsequentes do estudo.

##Atividade A3: Resultado da Pesquisa de Satisfação

Nesta etapa é realizada a consolidação da percepção dos clientes por meio da discretização da opinião, cálculo de percentuais e estimativa de intervalo de confiança via Bootstrap.

O objetivo é fornecer indicadores claros de satisfação geral e segmentada, apoiando decisões estratégicas da UVVine.

Fazer o resultado da Pesquisa de satisfação do cliente em porcentagem (%): * Geral * Por Sexo

###Atividade A3.1: Discretizar a Variável Qualitativa (OPINIÃO DO CLIENTE)

Nesta etapa, a variável `OPINIÃO DO CLIENTE` é transformada em um indicador binário de satisfação, permitindo estimar o percentual de clientes satisfeitos na base total e por sexo. Além disso, utiliza-se bootstrap para construir um intervalo de confiança de 95% para a satisfação geral.

[89]:
```
def AtividadeA3_1(B=3000, seed=42):
    col_op = "OPINIÃO DO CLIENTE"
    col_sexo = "SEXO"

    df = table.copy()

    def classificar_sentimento(texto):
        if pd.isna(texto):
            return np.nan

        t = str(texto).upper().strip()

        positivas = [
            "EXCELENTE", "ÓTIMO", "OTIMO", "PERFEITO", "IMPECÁVEL", "IMPECAVEL",
            "SUPEROU", "ADOREI", "GOSTEI", "RECOMENDO", "SATISFEITO",␣
↪"SATISFEITA",
            "BOA", "BOM", "EFICIENTE", "TOP", "MARAVILHOSAMENTE"
        ]

        neutras = [
            "INDIFERENTE", "NEUTRA", "NEUTRO", "SEM OPINIÃO", "SEM OPINIAO",
            "NÃO TENHO", "NAO TENHO", "COMUM", "REGULAR", "ACEITAVEL",␣
↪"ACEITÁVEL",
            "RAZOÁVEL", "RAZOAVEL"
        ]

        negativas = [
```

```
            "NADA DIGNO", "NÃO ATENDEU", "NAO ATENDEU", "PODERIA MELHORAR",
            "ESPERAVA MAIS", "NAO GOSTEI", "NÃO GOSTEI", "RUIM", "PÉSSIMO",␣
↪"PESSIMO"
        ]

        if any(p in t for p in positivas):
            return 1
        if any(n in t for n in negativas):
            return 0
        if any(n in t for n in neutras):
            return 0

        return 0

    df["SATISFEITO_BIN"] = df[col_op].apply(classificar_sentimento)
    df_valid = df.dropna(subset=["SATISFEITO_BIN"]).copy()

    n_valido = int(len(df_valid))
    if n_valido == 0:
        raise ValueError("Não há registros válidos para calcular a satisfação.")

    p_hat = float(df_valid["SATISFEITO_BIN"].mean())
    perc_geral = p_hat * 100

    rng = np.random.default_rng(seed)
    boot = (rng.binomial(n=n_valido, p=p_hat, size=B) / n_valido) * 100

    ic_inf = float(np.percentile(boot, 2.5))
    ic_sup = float(np.percentile(boot, 97.5))

    satisfacao_sexo = None
    if col_sexo in df_valid.columns:
        satisfacao_sexo = (
            df_valid.groupby(col_sexo)["SATISFEITO_BIN"]
            .mean()
            .mul(100)
            .sort_values(ascending=False)
        )

    RESULTADOS["A3.1"] = {
        "n_valido": n_valido,
        "satisfacao_geral_%": float(perc_geral),
        "ic95_%": (ic_inf, ic_sup),
        "bootstrap_%": boot,
        "por_sexo_%": satisfacao_sexo.to_dict() if satisfacao_sexo is not None␣
↪else None,
        "dados_validos": df_valid,
```

```
    }

    print("Resultado da pesquisa de satisfação calculado.")
```

[90]:
```
AtividadeA3_1()
resultado = RESULTADOS["A3.1"]
```

```
Resultado da pesquisa de satisfação calculado.
```

[91]:
```
resumo_a31 = pd.DataFrame(
    [
        {
            "N válidos": resultado["n_valido"],
            "Satisfação geral (%)": resultado["satisfacao_geral_%"],
            "IC 95% inferior": resultado["ic95_%"][0],
            "IC 95% superior": resultado["ic95_%"][1],
        }
    ]
)

resumo_a31[["Satisfação geral (%)", "IC 95% inferior", "IC 95% superior"]] = (
    resumo_a31[["Satisfação geral (%)", "IC 95% inferior", "IC 95% superior"]].
 ↪round(2)
)

display(resumo_a31)
```

```
   N válidos  Satisfação geral (%)  IC 95% inferior  IC 95% superior
0    1120000                 64.79             64.7            64.87
```

[92]:
```
if resultado["por_sexo_%"] is not None:
    resumo_sexo = pd.DataFrame(
        list(resultado["por_sexo_%"].items()),
        columns=["SEXO", "Satisfação (%)"]
    )
    resumo_sexo["Satisfação (%)"] = resumo_sexo["Satisfação (%)"].round(2)
    display(resumo_sexo)
```

```
        SEXO  Satisfação (%)
0  MASCULINO           64.82
1   FEMININO           64.55
```

[93]:
```
boot = resultado["bootstrap_%"]
estimativa = resultado["satisfacao_geral_%"]
ic_inf, ic_sup = resultado["ic95_%"]

plt.figure(figsize=(11, 5))
```

```
sns.histplot(
    boot,
    bins=35,
    stat="density",
    color="#A8DADC",
    edgecolor="white",
    alpha=0.75,
)

sns.kdeplot(
    boot,
    color="#1D3557",
    linewidth=2.4,
)

plt.axvline(estimativa, color="#E76F51", linestyle="-", linewidth=2.2,␣
 ↪label="Estimativa")
plt.axvline(ic_inf, color="#2A9D8F", linestyle="--", linewidth=2, label="IC␣
 ↪95%")
plt.axvline(ic_sup, color="#2A9D8F", linestyle="--", linewidth=2)

plt.title("Distribuição bootstrap da satisfação geral", fontsize=15,␣
 ↪fontweight="bold")
plt.xlabel("Satisfação (%)", fontsize=11)
plt.ylabel("Densidade", fontsize=11)
plt.grid(alpha=0.18)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
plt.show()
```

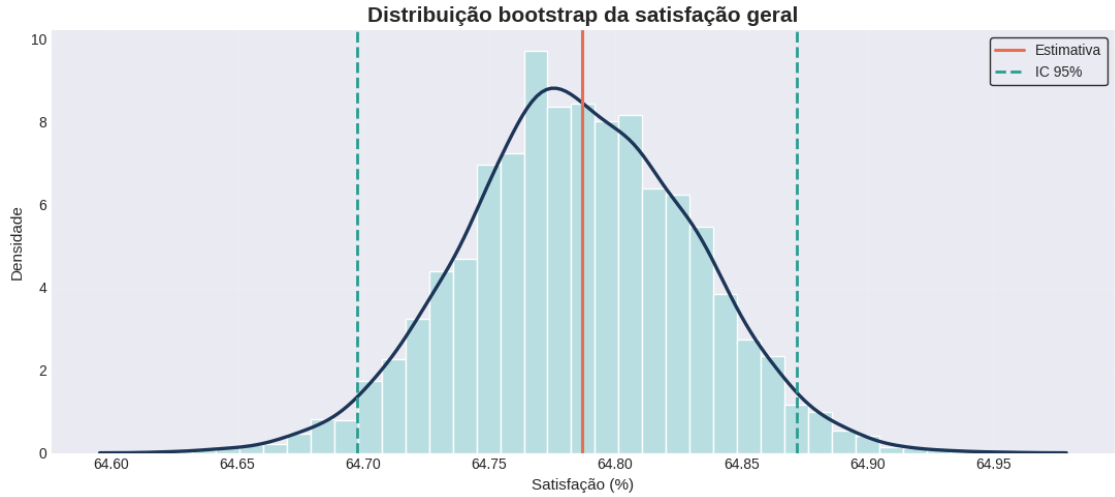

[94]:
```
if resultado["por_sexo_%"] is not None:
    resumo_sexo = pd.DataFrame(
        list(resultado["por_sexo_%"].items()),
        columns=["SEXO", "Satisfação (%)"]
    ).sort_values("Satisfação (%)")

    plt.figure(figsize=(9, 4.8))

    bars = plt.barh(
        resumo_sexo["SEXO"],
        resumo_sexo["Satisfação (%)"],
        color=["#F4A261", "#457B9D"][:len(resumo_sexo)],
        edgecolor="white",
        linewidth=0.8,
    )

    for bar, valor in zip(bars, resumo_sexo["Satisfação (%)"]):
        plt.text(
            bar.get_width() + 0.15,
            bar.get_y() + bar.get_height() / 2,
            f"{valor:.2f}%",
            va="center",
            fontsize=10,
        )

    plt.title("Satisfação por sexo", fontsize=15, fontweight="bold")
    plt.xlabel("Satisfação (%)", fontsize=11)
    plt.ylabel("Sexo", fontsize=11)
    plt.xlim(0, 100)
    plt.grid(axis="x", alpha=0.18)
    plt.tight_layout()
    sns.despine()
    plt.show()
```

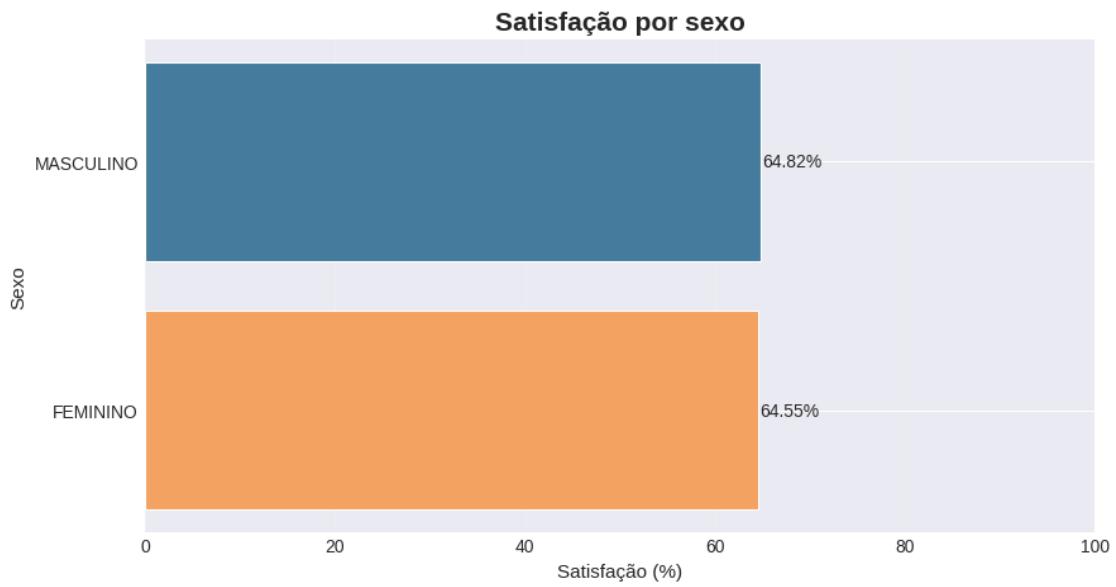

A discretização da variável `OPINIÃO DO CLIENTE` permitiu estimar a satisfação geral dos clientes em `64,79%`. O intervalo de confiança de 95% obtido por bootstrap variou de `64,70%` a `64,87%`, indicando baixa variabilidade amostral e boa precisão da estimativa.

Na análise segmentada por sexo, observou-se satisfação de `64,82%` entre os clientes do sexo `MASCULINO` e de `64,55%` entre os do sexo `FEMININO`. A diferença entre os grupos foi pequena, sugerindo comportamento bastante semelhante entre os segmentos analisados.

De modo geral, os resultados indicam predominância de avaliações satisfatórias na base, com estabilidade estatística da estimativa global e pouca diferença entre homens e mulheres. Assim, o indicador construído nesta etapa fornece uma medida objetiva e confiável da percepção dos clientes, servindo de base para a consolidação dos resultados da pesquisa de satisfação nas etapas seguintes do estudo.

3.0.5 Atividade A3.2: Análise bootstrap do resultado da pesquisa de satisfação

Nesta etapa, aprofunda-se a análise da satisfação dos clientes por meio da técnica bootstrap, com o objetivo de estimar a precisão da satisfação geral, calcular o erro padrão empírico e construir intervalos de confiança. Além disso, avalia-se a diferença de satisfação entre os grupos de sexo, permitindo verificar se há variação relevante entre os segmentos.

[95]:
```
def AtividadeA3_2(B=3000, seed=42):
    col_op = "OPINIÃO DO CLIENTE"
    col_sexo = "SEXO"

    df = table.copy()

    def classificar_sentimento(texto):
        if pd.isna(texto):
```

```
            return np.nan

        t = str(texto).upper().strip()

        positivas = [
            "EXCELENTE", "ÓTIMO", "OTIMO", "PERFEITO", "IMPECÁVEL", "IMPECAVEL",
            "SUPEROU", "ADOREI", "GOSTEI", "RECOMENDO", "SATISFEITO",␣
↪"SATISFEITA",
            "BOA", "BOM", "EFICIENTE", "TOP"
        ]

        neutras = [
            "INDIFERENTE", "NEUTRA", "NEUTRO", "SEM OPINIÃO", "SEM OPINIAO",
            "NÃO TENHO", "NAO TENHO", "COMUM", "REGULAR", "ACEITAVEL",␣
↪"ACEITÁVEL",
            "RAZOÁVEL", "RAZOAVEL"
        ]

        negativas = [
            "NADA DIGNO", "NÃO ATENDEU", "NAO ATENDEU",
            "PODERIA MELHORAR", "ESPERAVA MAIS"
        ]

        if any(p in t for p in positivas):
            return 1
        if any(n in t for n in negativas):
            return 0
        if any(n in t for n in neutras):
            return 0

        return 0

    df["SATISFEITO_BIN"] = df[col_op].apply(classificar_sentimento)
    df_valid = df.dropna(subset=["SATISFEITO_BIN"]).copy()

    n = len(df_valid)
    if n == 0:
        raise ValueError("Nenhum registro válido encontrado para a análise␣
↪bootstrap.")

    perc_geral = float(df_valid["SATISFEITO_BIN"].mean() * 100)

    rng = np.random.default_rng(seed)
    y = df_valid["SATISFEITO_BIN"].values

    boot = np.empty(B)
    for b in range(B):
```

```
        idx = rng.integers(0, n, n)
        boot[b] = y[idx].mean() * 100

    se_boot = float(np.std(boot, ddof=1))
    ic_inf = float(np.percentile(boot, 2.5))
    ic_sup = float(np.percentile(boot, 97.5))

    por_sexo = None
    dif_sexo = None
    ic_dif = None
    p_boot = None
    diff_boot = None

    if col_sexo in df_valid.columns:
        por_sexo = (
            df_valid.groupby(col_sexo)["SATISFEITO_BIN"]
            .mean()
            .mul(100)
            .round(2)
        )

        if {"MASCULINO", "FEMININO"}.issubset(set(por_sexo.index.astype(str))):
            y_m = df_valid.loc[df_valid[col_sexo] == "MASCULINO",␣
↪"SATISFEITO_BIN"].values
            y_f = df_valid.loc[df_valid[col_sexo] == "FEMININO",␣
↪"SATISFEITO_BIN"].values

            bm = np.empty(B)
            bf = np.empty(B)

            for b in range(B):
                bm[b] = y_m[rng.integers(0, len(y_m), len(y_m))].mean() * 100
                bf[b] = y_f[rng.integers(0, len(y_f), len(y_f))].mean() * 100

            diff_boot = bm - bf
            dif_sexo = float(por_sexo["MASCULINO"] - por_sexo["FEMININO"])
            ic_dif = (
                float(np.percentile(diff_boot, 2.5)),
                float(np.percentile(diff_boot, 97.5)),
            )
            p_boot = float(2 * min((diff_boot <= 0).mean(), (diff_boot >= 0).
↪mean()))

    RESULTADOS["A3.2"] = {
        "n": int(n),
        "satisfacao_geral_%": perc_geral,
        "ic95": (ic_inf, ic_sup),
```

```
        "se_boot": se_boot,
        "bootstrap_geral": boot,
        "por_sexo": por_sexo.to_dict() if por_sexo is not None else None,
        "dif_sexo_pp": dif_sexo,
        "ic_dif": ic_dif,
        "p_boot": p_boot,
        "bootstrap_dif": diff_boot,
    }

    print("Análise bootstrap da satisfação concluída.")
```

[96]:
```
AtividadeA3_2()
resultado = RESULTADOS["A3.2"]
```

```
Análise bootstrap da satisfação concluída.
```

[97]:
```
resumo_a32 = pd.DataFrame(
    [
        {
            "N válidos": resultado["n"],
            "Satisfação geral (%)": resultado["satisfacao_geral_%"],
            "Erro padrão bootstrap": resultado["se_boot"],
            "IC 95% inferior": resultado["ic95"][0],
            "IC 95% superior": resultado["ic95"][1],
        }
    ]
)

resumo_a32[["Satisfação geral (%)", "Erro padrão bootstrap", "IC 95% inferior",␣
↪"IC 95% superior"]] = (
    resumo_a32[["Satisfação geral (%)", "Erro padrão bootstrap", "IC 95%␣
↪inferior", "IC 95% superior"]].round(2)
)

display(resumo_a32)
```

```
   N válidos  Satisfação geral (%)  Erro padrão bootstrap  IC 95% inferior  \
0    1120000                 64.79                   0.05             64.7

   IC 95% superior
0            64.87
```

[98]:
```
if resultado["por_sexo"] is not None:
    resumo_sexo = pd.DataFrame(
        list(resultado["por_sexo"].items()),
        columns=["SEXO", "Satisfação (%)"]
    )
```

```
    resumo_sexo["Satisfação (%)"] = resumo_sexo["Satisfação (%)"].round(2)
    display(resumo_sexo)
```

```
        SEXO  Satisfação (%)
0   FEMININO           64.55
1  MASCULINO           64.82
```

[99]:
```
boot = resultado["bootstrap_geral"]
estimativa = resultado["satisfacao_geral_%"]
ic_inf, ic_sup = resultado["ic95"]

plt.figure(figsize=(11, 5))

sns.histplot(
    boot,
    bins=35,
    stat="density",
    color="#B8E1DD",
    edgecolor="white",
    alpha=0.75,
)

sns.kdeplot(
    boot,
    color="#1D3557",
    linewidth=2.5,
)

plt.axvline(estimativa, color="#E76F51", linewidth=2.2, label="Estimativa")
plt.axvline(ic_inf, color="#2A9D8F", linestyle="--", linewidth=2, label="IC␣
↪95%")
plt.axvline(ic_sup, color="#2A9D8F", linestyle="--", linewidth=2)

plt.title("Distribuição bootstrap da satisfação geral", fontsize=15,␣
↪fontweight="bold")
plt.xlabel("Satisfação (%)", fontsize=11)
plt.ylabel("Densidade", fontsize=11)
plt.grid(alpha=0.18)
plt.legend(frameon=True, edgecolor="black")
plt.tight_layout()
sns.despine()
plt.show()
```

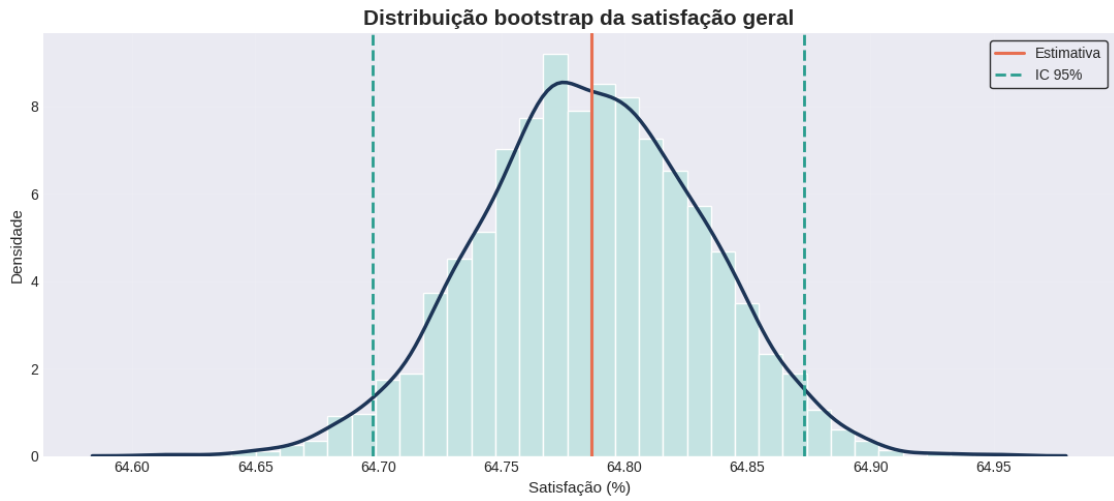

[100]:
```
if resultado["por_sexo"] is not None:
    resumo_sexo = pd.DataFrame(
        list(resultado["por_sexo"].items()),
        columns=["SEXO", "Satisfação (%)"]
    ).sort_values("Satisfação (%)")

    plt.figure(figsize=(9, 4.8))

    bars = plt.barh(
        resumo_sexo["SEXO"],
        resumo_sexo["Satisfação (%)"],
        color=["#F4A261", "#457B9D"][:len(resumo_sexo)],
        edgecolor="white",
        linewidth=0.8,
    )

    for bar, valor in zip(bars, resumo_sexo["Satisfação (%)"]):
        plt.text(
            bar.get_width() + 0.15,
            bar.get_y() + bar.get_height() / 2,
            f"{valor:.2f}%",
            va="center",
            fontsize=10,
        )

    plt.title("Satisfação por sexo", fontsize=15, fontweight="bold")
    plt.xlabel("Satisfação (%)", fontsize=11)
    plt.ylabel("Sexo", fontsize=11)
    plt.xlim(0, 100)
    plt.grid(axis="x", alpha=0.18)
```

```
    plt.tight_layout()
    sns.despine()
    plt.show()
```

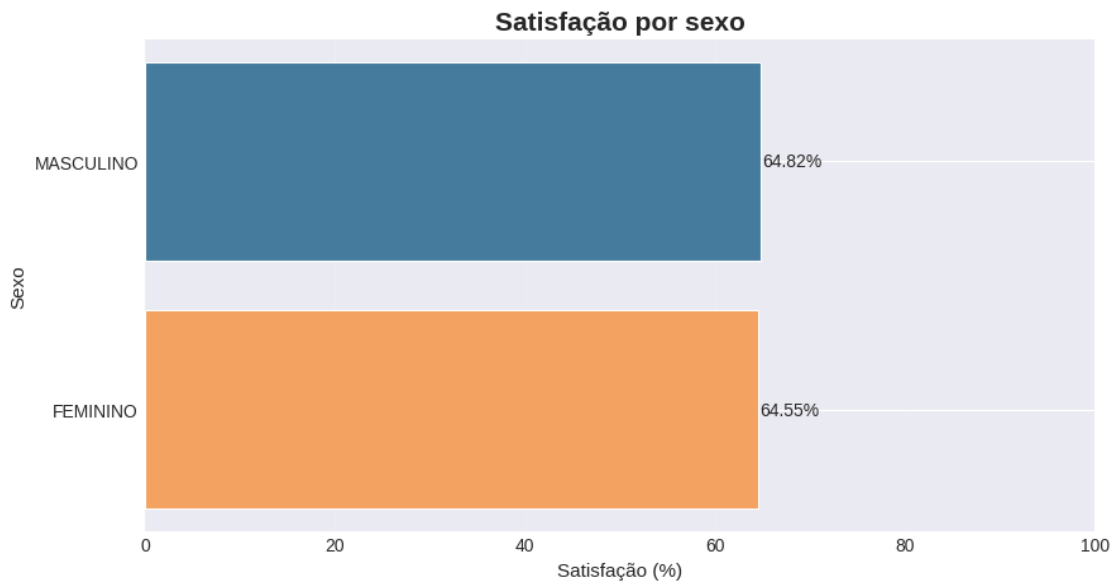

[101]:
```
if resultado["bootstrap_dif"] is not None:
    diff_boot = resultado["bootstrap_dif"]
    dif_obs = resultado["dif_sexo_pp"]
    ic_inf_dif, ic_sup_dif = resultado["ic_dif"]

    plt.figure(figsize=(11, 5))

    sns.histplot(
        diff_boot,
        bins=35,
        stat="density",
        color="#D8E2DC",
        edgecolor="white",
        alpha=0.80,
    )

    sns.kdeplot(
        diff_boot,
        color="#264653",
        linewidth=2.4,
    )
```

```
    plt.axvline(0, color="#D62828", linestyle="--", linewidth=2, label="Sem␣
↪diferença")
    plt.axvline(dif_obs, color="#F77F00", linewidth=2.2, label="Diferença␣
↪observada")
    plt.axvline(ic_inf_dif, color="#2A9D8F", linestyle=":", linewidth=2,␣
↪label="IC 95%")
    plt.axvline(ic_sup_dif, color="#2A9D8F", linestyle=":", linewidth=2)

    plt.title("Distribuição bootstrap da diferença de satisfação por sexo",␣
↪fontsize=15, fontweight="bold")
    plt.xlabel("Diferença em pontos percentuais", fontsize=11)
    plt.ylabel("Densidade", fontsize=11)
    plt.grid(alpha=0.18)
    plt.legend(frameon=True, edgecolor="black")
    plt.tight_layout()
    sns.despine()
    plt.show()
```

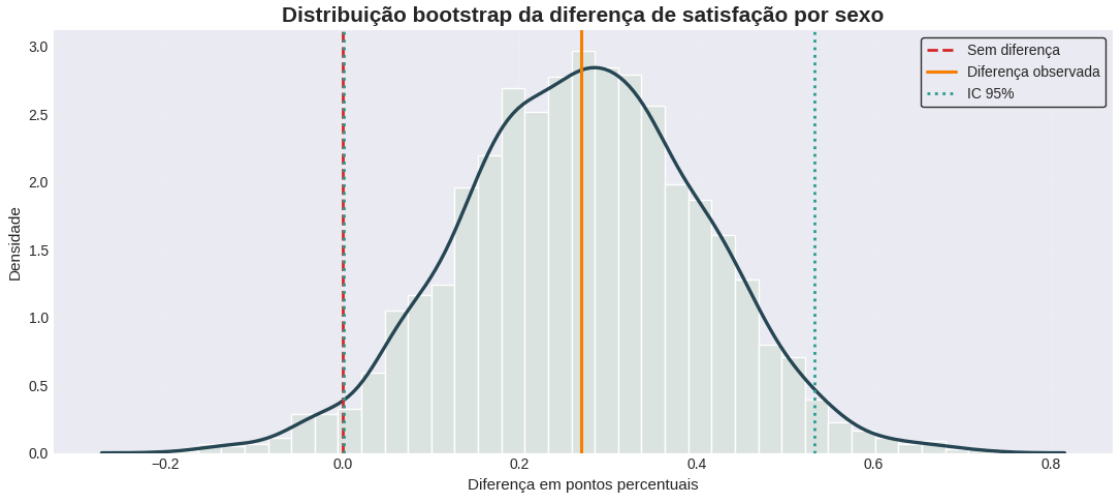

A análise bootstrap confirmou a estabilidade da estimativa de satisfação geral dos clientes, fixada em `64,79%`. O intervalo de confiança de 95% variou de `64,70%` a `64,87%`, com erro padrão empírico de `0,05`, indicando baixa variabilidade amostral e elevada precisão da estimativa.

Na segmentação por sexo, observou-se satisfação de `64,82%` entre os clientes do sexo `MASCULINO` e de `64,55%` entre os do sexo `FEMININO`, o que corresponde a uma diferença observada de aproximadamente `0,27` ponto percentual. Apesar dessa diferença favorável ao grupo masculino, a distribuição bootstrap da diferença mostrou intervalo de confiança de 95% incluindo o valor zero, indicando ausência de evidência estatística robusta de diferença entre os grupos.

De modo geral, os resultados reforçam a consistência do indicador de satisfação construído para a base analisada e mostram que a percepção dos clientes é relativamente homogênea entre homens e mulheres. Assim, a técnica bootstrap contribuiu para quantificar a incerteza da estimativa geral

e para sustentar a interpretação de que não há diferença relevante de satisfação por sexo nesta amostra.

3.0.6 Atividade A3.3: Resultado final da pesquisa de satisfação

Nesta etapa, consolidam-se os resultados obtidos nas Atividades A3.1 e A3.2, reunindo a estimativa de satisfação geral, o intervalo de confiança bootstrap e a comparação por sexo. O objetivo é produzir um resumo final, com interpretação estatística e leitura gerencial, pronto para compor o texto do TCC.

[106]:
```
def AtividadeA3_3(limiar_relevancia_pp=1.0):
    if "A3.1" not in RESULTADOS:
        raise ValueError("Execute a Atividade A3.1 antes desta etapa.")

    r31 = RESULTADOS["A3.1"]
    r32 = RESULTADOS.get("A3.2")

    n_valido = r32["n"] if r32 is not None else r31["n_valido"]
    satisfacao_geral = r32["satisfacao_geral_%"] if r32 is not None else␣
↪r31["satisfacao_geral_%"]

    ic = r32["ic95"] if r32 is not None else r31["ic95_%"]
    ic_inf, ic_sup = float(ic[0]), float(ic[1])

    se_boot = r32["se_boot"] if r32 is not None else None

    por_sexo = None
    if r32 is not None and r32.get("por_sexo") is not None:
        por_sexo = r32["por_sexo"]
    elif r31.get("por_sexo_%") is not None:
        por_sexo = r31["por_sexo_%"]

    dif_sexo = r32.get("dif_sexo_pp") if r32 is not None else None
    ic_dif = r32.get("ic_dif") if r32 is not None else None
    p_boot = r32.get("p_boot") if r32 is not None else None

    linhas = [
        {
            "Segmento": "Geral",
            "Satisfação (%)": round(float(satisfacao_geral), 2),
            "IC95% inferior": round(ic_inf, 2),
            "IC95% superior": round(ic_sup, 2),
            "Erro padrão bootstrap": round(float(se_boot), 4) if se_boot is not␣
↪None else None,
        }
    ]

    if por_sexo is not None:
```

```
        for grupo, valor in por_sexo.items():
            linhas.append(
                {
                    "Segmento": f"Sexo: {grupo}",
                    "Satisfação (%)": round(float(valor), 2),
                    "IC95% inferior": None,
                    "IC95% superior": None,
                    "Erro padrão bootstrap": None,
                }
            )

    tabela_final = pd.DataFrame(linhas)

    interpretacao_sexo = "Não foi possível estimar a diferença de satisfação␣
↪por sexo."
    relevancia_pratica = None

    if dif_sexo is not None and ic_dif is not None and p_boot is not None:
        significancia = (
            "estatisticamente significativa"
            if p_boot < 0.05
            else "não estatisticamente significativa"
        )

        relevancia_pratica = (
            "relevante do ponto de vista prático"
            if abs(dif_sexo) >= limiar_relevancia_pp
            else "pequena do ponto de vista prático"
        )

        interpretacao_sexo = (
            f"A diferença de satisfação entre MASCULINO e FEMININO foi de␣
↪{dif_sexo:.2f} pontos percentuais, "
            f"com IC95% entre {ic_dif[0]:.2f} e {ic_dif[1]:.2f} e p-valor␣
↪bootstrap de {p_boot:.4f}. "
            f"Assim, a diferença é {significancia} e {relevancia_pratica}."
        )

    texto_tcc = (
        f"A pesquisa de satisfação da UVVine foi consolidada a partir de␣
↪{int(n_valido):,} respostas válidas. "
        f"A satisfação geral estimada foi de {float(satisfacao_geral):.2f}%, "
        f"com intervalo de confiança bootstrap de 95% entre {ic_inf:.2f}% e␣
↪{ic_sup:.2f}%."
    )

    if se_boot is not None:
```

```
        texto_tcc += f" O erro padrão empírico estimado foi de {float(se_boot):.
↪4f}."

    texto_tcc += " " + interpretacao_sexo

    RESULTADOS["A3.3"] = {
        "n_valido": int(n_valido),
        "satisfacao_geral_%": float(satisfacao_geral),
        "ic95_%": (ic_inf, ic_sup),
        "se_bootstrap": float(se_boot) if se_boot is not None else None,
        "por_sexo_%": por_sexo,
        "dif_sexo_pp": float(dif_sexo) if dif_sexo is not None else None,
        "ic_dif": ic_dif,
        "p_boot": float(p_boot) if p_boot is not None else None,
        "relevancia_pratica": relevancia_pratica,
        "tabela_final": tabela_final,
        "interpretacao_sexo": interpretacao_sexo,
        "texto_tcc": texto_tcc,
    }
```

[108]:
```
AtividadeA3_3(limiar_relevancia_pp=1.0)
resultado = RESULTADOS["A3.3"]
```

[109]:
```
display(resultado["tabela_final"])
```

```
          Segmento  Satisfação (%)  IC95% inferior  IC95% superior  \
0            Geral           64.79            64.7           64.87
1   Sexo: FEMININO           64.55             NaN             NaN
2  Sexo: MASCULINO           64.82             NaN             NaN

   Erro padrão bootstrap
0                 0.0453
1                    NaN
2                    NaN
```

A pesquisa de satisfação da UVVine foi consolidada a partir de `1.120.000` respostas válidas. A satisfação geral estimada foi de `64,79%`, com intervalo de confiança bootstrap de `95%` entre `64,70%` e `64,87%`, além de erro padrão empírico de `0,0453`. Esses resultados indicam elevada precisão da estimativa e reforçam a estabilidade do indicador de satisfação construído para a base analisada.

Na segmentação por sexo, observou-se satisfação de `64,82%` entre os clientes do sexo `MASCULINO` e de `64,55%` entre os do sexo `FEMININO`, resultando em diferença de aproximadamente `0,27` ponto percentual. Considerando a análise bootstrap da diferença, conclui-se que essa variação é pequena do ponto de vista prático e não altera de forma relevante a interpretação geral da satisfação dos clientes.

De modo geral, os resultados consolidados indicam predominância de avaliações satisfatórias na base da UVVine, com baixa incerteza estatística e pouca variação entre os segmentos analisados. Assim, a pesquisa de satisfação fornece um indicador confiável e útil para apoiar decisões gerenciais

relacionadas à experiência do cliente.

---

4 RELATÓRIO FINAL – PARTE 1

4.1 Análise Estatística da Base de Clientes — UVVine

4.2 1. Introdução

Este relatório apresenta os resultados consolidados da Parte 1 do projeto da UVVine, contemplando as etapas de estratificação amostral, testes estatísticos e análise descritiva da base de clientes.

O objetivo central desta etapa é responder à seguinte questão:

Qual é o tamanho ideal da amostra para representar adequadamente a população de clientes da UVVine?

A resposta é construída com base nos resultados obtidos nas Atividades **A1 (Estratificação Amostral da População)** e **A2 (Estatística Descritiva)**, com apoio complementar das análises inferenciais e da técnica bootstrap.

4.3 2. Atividade A1 — Estratificação Amostral da População

4.3.1 2.1 Determinação do tamanho ideal da amostra

A determinação do tamanho ideal da amostra foi realizada com base na estabilização do erro-padrão da média da variável **TOTAL (R$)**. Para isso, foram simulados diferentes tamanhos amostrais e identificado o menor valor de `n` para o qual o erro-padrão estimado se tornou menor ou igual ao erro-padrão médio.

Os resultados mostraram:

- População disponível: **1.120.000 registros**;
- Média de **TOTAL (R$)**: **851,19**;
- Erro-padrão-médio estimado: **3,7514**;
- Intervalo de confiança de 95% para a média: [**843,83 ; 858,54**];
- **Tamanho ideal da amostra: 51.400 observações**.

Esse resultado indica que, mesmo diante de uma população muito ampla, uma amostra de **51.400 registros** é suficiente para representar a base com precisão estatística adequada.

4.3.2 2.2 Análise de outliers

A análise de outliers pelo critério do intervalo interquartil mostrou presença de valores extremos principalmente nas variáveis monetárias:

- **RENDA BRUTO (R$)**: **17,39%** de outliers;
- **TOTAL (R$)**: **9,54%** de outliers;

- **NOTA DE SATISFAÇÃO (%)**: **6,88%**, porém com `IQR = 0`, tornando o método inadequado para tratamento nessa variável.

A variável **NOTA DE SATISFAÇÃO (%)** apresentou forte concentração no valor **68,68**, responsável por **93,12%** dos registros, o que evidencia comportamento altamente concentrado e não compatível com uma distribuição simétrica.

4.3.3 2.3 Testes de hipóteses

Os testes realizados na Atividade A1.3 reforçaram a validade da amostra definida em A1.1.

O teste de normalidade indicou rejeição da hipótese de normalidade para as principais variáveis numéricas, especialmente em razão de assimetria, caudas longas e concentração de valores. Ainda assim, considerando o grande tamanho amostral, a inferência sobre médias permaneceu válida com apoio do **Teorema Central do Limite** e validação por **bootstrap**.

Na comparação entre a população e a amostra ideal para a variável **TOTAL (R$)**, observou-se:

- Média populacional: **851,19**;
- Média da amostra ideal: **853,36**;
- Teste de hipótese para a média: **p = 0,5644**;
- Intervalo de confiança bootstrap da diferença incluindo zero.

Assim, **não houve evidência estatística para rejeitar a hipótese de que a amostra ideal representa adequadamente a população**, o que confirma a consistência do tamanho amostral de **51.400** observações.

4.4 3. Atividade A2 — Estatística Descritiva

4.4.1 3.1 Variáveis quantitativas

A análise descritiva das variáveis quantitativas revelou diferenças importantes de dispersão, concentração e assimetria entre os indicadores numéricos da base.

Os principais destaques foram:

- Maior variabilidade relativa: **TOTAL (R$)**, com **coeficiente de variação = 1,0011**;
- Maior percentual de outliers: **RENDA BRUTO (R$)**, com **17,39%**;
- Maior assimetria: **NOTA DE SATISFAÇÃO (%)**, com **skew = 5,9103**;
- Assimetria também relevante em **TOTAL (R**$)**(**$1,9738$**)e**$**RENDABRUTO(R$**) (**1,4110**).

Esses resultados mostram que a base apresenta distribuições heterogêneas, presença de valores extremos e forte assimetria em algumas variáveis, especialmente nas de natureza financeira e na variável de satisfação.

4.4.2 3.2 Variáveis qualitativas

A análise das variáveis qualitativas mostrou ausência de valores ausentes nas categorias avaliadas, o que favorece a consistência da leitura descritiva.

Os principais resultados foram:

- **SEXO** apresentou alta concentração em **MASCULINO** (**86,95%**);
- **REGIÃO** apresentou predominância do **SUDESTE** (**67,05%**);
- **ESTADO CIVIL** apresentou predominância de **CASADO** (**54,98%**);
- **TIPO DA CONTA** apresentou predominância de **ESSENTIAL** (**58,05%**);
- **DEPENDENTES** concentrou-se na categoria **1** (**52,99%**);
- **OPINIÃO DO CLIENTE** foi a variável de maior diversidade, com **25 categorias** e categoria modal de apenas **15,43%**.

Esses resultados mostram que algumas variáveis qualitativas possuem forte concentração em categorias dominantes, enquanto outras apresentam maior diversidade de perfis.

4.5 4. Resultado da Pesquisa de Satisfação

A discretização da variável **OPINIÃO DO CLIENTE** permitiu estimar a satisfação geral dos clientes da UVVine em:

- **64,79% de satisfação geral**;
- Intervalo de confiança bootstrap de 95%: [**64,70% ; 64,87%**];
- Erro-padrão empírico: **0,0453**.

Na segmentação por sexo, observou-se:

- **MASCULINO**: **64,82%**;
- **FEMININO**: **64,55%**.

A diferença observada entre os grupos foi de aproximadamente **0,27 ponto percentual**, sendo pequena do ponto de vista prático. Assim, a satisfação mostrou-se relativamente homogênea entre os segmentos analisados.

4.6 5. Conclusão — Resposta à Pergunta Principal

4.6.1 Qual é o tamanho ideal da amostra?

Com base nos resultados obtidos, conclui-se que:

O tamanho ideal da amostra para representar a população de clientes da UVVine é de 51.400 observações.

Essa conclusão se justifica pelos seguintes pontos:

1. O valor foi obtido a partir da estabilização do erro-padrão da média da variável **TOTAL (R$)**.
2. A amostra ideal foi definida com base em critério quantitativo objetivo, associado à precisão estatística da estimativa.
3. O teste de hipótese para comparação entre média amostral e média populacional não indicou diferença estatisticamente significativa (`p = 0,5644`).
4. A validação por bootstrap reforçou que a diferença entre a amostra ideal e a população é compatível com a variabilidade esperada.

5. A análise descritiva mostrou presença de assimetria e outliers, mas sem comprometer a representatividade da amostra, especialmente diante do grande volume de dados e da robustez do Teorema Central do Limite.

Portanto, **uma amostra de 51.400 clientes é estatisticamente suficiente para representar a população da UVVine com precisão, confiabilidade e consistência metodológica**.

4.7 6. Considerações Finais

Os resultados da Parte 1 demonstram que a base de clientes da UVVine apresenta características importantes de heterogeneidade, presença de valores extremos e distribuições não normais em diversas variáveis. Ainda assim, a combinação entre estratificação amostral, estatística descritiva, testes de hipóteses e validação por bootstrap proporcionou uma base metodológica sólida para a tomada de decisão.

Dessa forma, esta etapa conclui que a população foi adequadamente caracterizada e que o tamanho amostral definido é confiável para sustentar as análises da Parte 2 do projeto, voltadas à modelagem e apresentação dos resultados.

5 REFERÊNCIAS BIBLIOGRÁFICAS

5.1 Amostragem e tamanho de amostra

COCHRAN, W. G. *Sampling Techniques*. 3. ed. New York: John Wiley & Sons, 1977.

KISH, L. *Survey Sampling*. New York: John Wiley & Sons, 1965.

5.2 Testes de hipóteses

FIELD, A. *Discovering Statistics Using IBM SPSS Statistics*. 4. ed. London: SAGE Publications, 2013.

SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality. *Biometrika*, v. 52, n. 3-4, p. 591-611, 1965.

5.3 Bootstrap e reamostragem

EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. New York: Chapman and Hall/CRC, 1993.

DAVISON, A. C.; HINKLEY, D. V. *Bootstrap Methods and Their Application*. Cambridge: Cambridge University Press, 1997.

5.4 Documentação técnica

SCIPY DEVELOPERS. *scipy.stats — Statistical functions*. Disponível em: https://docs.scipy.org/doc/scipy/reference/stats.html. Acesso em: 19 mar. 2026.

STATSMODELS DEVELOPERS. *Statsmodels: Statistical modeling and econometrics*. Disponível em: https://www.statsmodels.org/. Acesso em: 19 mar. 2026.

PANDAS DEVELOPMENT TEAM. *pandas: Python Data Analysis Library*. Disponível em: https://pandas.pydata.org/. Acesso em: 19 mar. 2026.

5.5 Contexto de negócio

FORNELL, C.; JOHNSON, M. D.; ANDERSON, E. W.; CHA, J.; BRYANT, B. E. The American Customer Satisfaction Index: Nature, purpose, and findings. *Journal of Marketing*, v. 60, n. 4, p. 7-18, 1996.

[ ]:
```
!apt-get update
!apt-get install -y texlive-xetex texlive-fonts-recommended␣
↪texlive-plain-generic pandoc
!jupyter nbconvert --to pdf "/content/LENON_MERLO_PARTE_1_TCC.ipynb"
```

```
[NbConvertApp] Converting notebook /content/LENON_MERLO_PARTE_1_TCC.ipynb to
html
[NbConvertApp] WARNING | Alternative text is missing on 72 image(s).
[NbConvertApp] Writing 5824523 bytes to /content/LENON_MERLO_PARTE_1_TCC.html
```

[ ]: